




POLITÉCNICA



Universidad
Politécnica
de Madrid

**ETSI SISTEMAS
INFORMÁTICOS**

Desarrollo de una Solución de Inteligencia de Negocio para el Análisis del Rendimiento Académico de la ETSISI

Proyecto Fin de Grado

Grado en Ingeniería de Software

Autor:
Zebin Li

Tutor:
Borja Bordel Sánchez

Junio, 2026

UNIVERSIDAD POLITÉCNICA DE MADRID
ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA DE
SISTEMAS INFORMÁTICOS



**Desarrollo de una Solución de
Inteligencia de Negocio
para el Análisis del Rendimiento
Académico de la ETSISI**

Proyecto Fin de Grado

Grado en Ingeniería de Software

Curso académico 2025-2026

Autor:
Zebin Li

Tutor:
Borja Bordel Sánchez

2026 Junio

Agradecimientos

En primer lugar, quiero expresar mi más sincero agradecimiento a mi tutor, Borja Bordel Sánchez por su guía, paciencia y por confiar en este proyecto desde el principio. Sus correcciones y consejos han sido fundamentales para transformar una idea en este trabajo de fin de grado.

A mis padres y a mi familia, por ser mi apoyo incondicional no solo durante estos meses de TFG, sino a lo largo de toda la carrera. Gracias por creer en mí incluso cuando yo mismo dudaba y por darme las herramientas para llegar hasta aquí.

Por último, a todas aquellas personas que, de una forma u otra, han formado parte de esta etapa que hoy cierro con orgullo.

Resumen

Este proyecto describe el diseño e implementación de una solución integral de inteligencia de negocio orientada al análisis avanzado del rendimiento académico en el entorno universitario. El objetivo central del proyecto es la transformación de datos brutos, originalmente dispersos y heterogéneos, en un activo de información estratégica que facilite la toma de decisiones basada en evidencia para los responsables docentes y gestores académicos de la ETSISI.

La metodología se articula a través de un ciclo de vida completo de ingeniería de datos, comenzando por una fase crítica de Extracción, Transformación y Carga. Utilizando la herramienta Talend Open Studio, se ha desarrollado un flujo de trabajo capaz de procesar y consolidar registros históricos correspondientes a siete cursos académicos. Esta información se almacena en una base de datos centralizada bajo el gestor MySQL, la cual actúa como soporte de almacenamiento y plataforma para la ejecución de auditorías de calidad. Durante esta etapa, se han implementado rigurosos controles de calidad, validaciones técnicas y transformaciones mediante componentes como `tUnite`, `tMap` y `tUniqueRow`, permitiendo el filtro, enriquecimiento y estandarización de los datos, la normalización de inconsistencias, la gestión de valores nulos y la eliminación de redundancias. El resultado es un repositorio depurado de 5.047 registros únicos cuya integridad es validada mediante consultas SQL de control.

La fase de explotación de datos culmina con el desarrollo de un dashboard interactivo en Power BI. Es fundamental señalar que, mientras MySQL garantiza la persistencia y limpieza de los datos, el diseño del modelo multidimensional (esquema en estrella) se ha ejecutado directamente en el motor de Power BI. Mediante el uso de lógica DAX y técnicas de modelado relacional, se ha estructurado la información en tres páginas especializadas: Visión General, Análisis de asignatura y Análisis de titulaciones.

Los resultados demuestran que la implementación de esta arquitectura no solo automatiza la generación de informes, reduciendo tiempos de respuesta de semanas a segundos, sino que dota a la institución de una herramienta robusta para la planificación estratégica. Finalmente, el trabajo sienta las bases para futuras líneas de investigación, como la aplicación de modelos de analítica predictiva para la detección temprana del riesgo de abandono escolar.

Abstract

This project describes the design and implementation of a comprehensive business intelligence solution for the advanced analysis of academic performance in a university environment. The main objective of the project is to transform raw, scattered, and heterogeneous data into a strategic information asset that facilitates evidence-based decision-making for faculty leads and academic managers at ETSISI.

The methodology is structured around a complete data engineering lifecycle, starting with a critical Extraction, Transformation, and Loading phase. Using Talend Open Studio, a workflow was developed to process and consolidate historical records spanning seven academic years. This information is stored in a centralized MySQL database, which acts as the storage platform and an engine for executing data quality audits. During this stage, rigorous quality controls, technical validations, and transformations were implemented using components such as `tUnite`, `tMap`, and `tUniqueRow`, allowing for data filtering, enrichment, standardization, the normalization of inconsistencies, null value management, and redundancy elimination. This resulted in a clean repository of 5,047 unique records, whose integrity is validated through SQL control queries.

The data exploitation phase culminates with the development of an interactive dashboard in Power BI. It is essential to note that while MySQL guarantees data persistence and cleanliness, the multidimensional model design (star schema) was executed directly within the Power BI engine. Using DAX logic and relational modeling techniques, the information was structured into three specialized pages: General View, Course Analysis, and Degree Analysis.

The results demonstrate that implementing this architecture not only automates reporting, reducing response times from weeks to seconds, but also provides the institution with a robust tool for strategic planning. Finally, this work lays the foundation for future research lines, such as the application of predictive analytics models for the early detection of student dropout risk.

Índice

Agradecimientos	I
Resumen	II
Abstract	III
1. Introducción	1
1.1. Contexto	1
1.2. Objetivos	2
1.3. Motivación	2
1.4. Estructura del documento	3
2. Estado del arte	5
2.1. Evolución de los Sistemas de Apoyo a la Decisión y Business Intelligence	5
2.2. Integración de Datos y Evolución de los Procesos ETL	5
2.2.1. Perspectiva Histórica y Consolidación del ETL	5
2.2.2. La Revolución Cloud y el Cambio hacia el ELT	6
2.3. Modelado Dimensional: El Esquema en Estrella	7
2.3.1. Ventajas del Modelado Dimensional en Proyectos de Business Intelligence	7
2.4. Visualización de Datos y Dashboards Interactivos	8
2.4.1. Evolución hacia el Business Intelligence de Autoservicio	8
2.4.2. Técnicas de Análisis Visual en el Ámbito Académico	9
2.5. Casos de Uso de Inteligencia de Negocio en el Ámbito Académico	9
2.5.1. Georgia Institute of Technology	10
2.5.2. Arizona State University	10
2.5.3. Universidad de Murcia	10
2.5.4. Tendencias Comunes en el Sector Educativo	10
2.6. Marco Tecnológico	11
2.6.1. Microsoft Excel y CSV	11
2.6.2. Talend Open Studio	12
2.6.3. MySQL	13
2.6.4. Microsoft Power BI	13
2.6.5. Git y GitHub	14
3. Desarrollo del proyecto	15
3.1. Diseño del proyecto	15
3.1.1. Arquitectura	15
3.1.2. Componentes Principales	15
3.2. Diseño de la transformación por capas	16
3.2.1. Capa de Origen de Datos	17
3.2.2. Capa de Integración y Procesamiento	17
3.2.3. Capa de Almacenamiento Relacional	17
3.2.4. Capa de Modelado Dimensional y Visualización	17
3.3. Implementación del proceso ETL	17
3.3.1. Configuración Inicial	18
3.3.2. Carga de datos crudos	21
3.3.3. Unificación de los datos crudos	24

3.4.	Transformación de la tabla unificada	25
3.4.1.	Filtro y selección de datos	25
3.4.2.	Enriquecimiento	26
3.4.3.	Estandarización	27
3.4.4.	Fase de carga de datos a la BBDD	29
3.5.	Implementación de Power BI	31
3.5.1.	Conexión y extracción de datos desde MySQL	32
3.5.2.	Creación del campo categórico Repetidor_Nuevo mediante agrupamiento	33
3.5.3.	Métrica de Tasa de Atascamiento por Asignatura	35
3.5.4.	Modelado de Datos: Arquitectura de Esquema en Estrella	36
3.5.5.	Diccionario de Datos del Modelo Dimensional	40
4.	Resultados	44
4.1.	Resultados obtenidos	44
4.1.1.	Visualización de Datos y Diseño del Dashboard	44
4.2.	Implementación de pruebas y resultados	47
4.2.1.	Objetivos de las pruebas	47
4.2.2.	Pruebas de integridad en el proceso ETL	47
4.2.3.	Lecciones Aprendidas	51
5.	Conclusiones y trabajos futuros	53
5.1.	Conclusiones	53
5.1.1.	Logros Principales	53
5.1.2.	Impacto en la Toma de Decisiones	53
5.2.	Desafíos y Limitaciones del Proyecto	54
5.2.1.	Limitaciones Tecnológicas y de Software	54
5.3.	Líneas Futuras	55
5.3.1.	Analítica Predictiva y Machine Learning	55
5.3.2.	Automatización del ciclo de carga y monitorización continua	56
5.3.3.	Migración a Entornos Cloud y Alta Disponibilidad	56
5.3.4.	Enriquecimiento con Fuentes de Datos Externas	56
6.	Aspectos Éticos, Legales y Medioambientales	58
6.1.	Impacto Social y Educativo	58
6.2.	Impacto Medioambiental y Sostenibilidad	58
6.3.	Consideraciones Éticas y Privacidad	59
6.3.1.	Ética y Privacidad de los Datos	59
6.3.2.	Eficiencia en la Gestión Institucional	59
	Bibliografía	60

Índice de tablas

1.	Diccionario de datos de la tabla de hechos Fact_rendimiento. . . .	41
2.	Diccionario de datos de la dimensión dim_asignatura.	42
3.	Diccionario de datos de la dimensión dim_plan_de_estudio. . . .	42
4.	Diccionario de datos de la dimensión dim_tiempo.	43
5.	Especificación del caso de prueba unitaria para la limpieza de texto.	51

Índice de figuras

1.	Diseño del proceso ETL.	6
2.	Ejemplo de un modelo estrella.	8
3.	Excel.	12
4.	Talend.	12
5.	MySQL.	13
6.	PowerBI.	14
7.	GitHub.	14
8.	Arquitectura ETL del proyecto	15
9.	creación de un nuevo proyecto local en Talend	18
10.	Interfaz principal de Talend y vista del repositorio de proyecto	18
11.	Configuración de la conexión local a MySQL	19
12.	Sentencias de creación de la base de datos y la tabla destino	19
13.	Inicialización del repositorio local mediante línea de comandos.	20
14.	Configuración del repositorio remoto en la plataforma GitHub.	20
15.	Verificación de los archivos sincronizados en el repositorio remoto.	21
16.	Sección de metadata en el repositorio de Talend	21
17.	Panel del paso 1 de configuración del componente de lectura CSV.	22
18.	Panel del paso 2 de configuración del componente de lectura CSV.	22
19.	Panel del paso 3 de configuración del componente de lectura CSV.	23
20.	Carga de datos crudos finalizada	24
21.	Unificación de datos mediante el componente tUnite.	25
22.	Tabla inicial.	26
23.	Tabla filtrado y seleccionado.	26
24.	Tabla unificada después del enriquecimiento	27
25.	Filtro de las claves primarias	28
26.	Tabla unificada después de la estandarización	29
27.	Flujo ETL después de la transformación	29
28.	Configuración del componente tDBOutput.	30
29.	Flujo de datos completo del proceso de ETL.	31
30.	Resultado de la consulta de verificación en MySQL.	31
31.	Configuración de los parámetros de red para la conexión local con MySQL.	32
32.	Autenticación para conectar con MySql	32
33.	Navegador de tablas y sus registros	33
34.	Configuración del grupo de datos Repetidor_Nuevo en Power BI.	34
35.	Aplicación de las etiquetas de grupo en las leyendas de los gráficos del dashboard.	34
36.	Ejemplo de una dimension creada.	38
37.	Tabla de hecho creada.	39
38.	Modelo de estrella.	40
39.	Página de Visión General.	45
40.	Página de análisis comparativo entre estudiantes nuevos y repetidores.	46
41.	Página de análisis de titulaciones.	47

42.	Código de la prueba de integridad	48
43.	Sentencia SQL para la validación de integridad y rangos numéricos.	48
44.	Resultado de la consulta de integridad.	48
45.	Resultado de la ejecución de cargar datos sin prueba de unicidad.	49
46.	Resultado de la ejecución de cargar datos con prueba de unicidad.	49
47.	Resultado de la ejecución de la consulta de prueba de la unicidad de la clave compuesta.	49
48.	Consulta para detectar error de tilde	50
49.	Resultado de la misma consulta después de aplicar los métodos .	51

Capítulo 1

Introducción

1.1. Contexto

En la última década, el avance de las tecnologías de la información y la digitalización global han propiciado un crecimiento exponencial en la generación y gestión de datos. En la actualidad, las organizaciones se enfrentan al desafío de procesar volúmenes masivos de registros que se producen a una velocidad y variedad sin precedentes. Sin embargo, la mera acumulación de estos activos digitales no garantiza una ventaja estratégica si no se dispone de las infraestructuras adecuadas para transformar el dato bruto en conocimiento útil para la toma de decisiones.

Tradicionalmente, el análisis de la información en diversos sectores se ha realizado mediante informes estáticos o herramientas de ofimática desconectadas, generadas manualmente de forma periódica. Este enfoque tradicional presenta limitaciones críticas en el entorno competitivo actual: la falta de inmediatez en la consulta, la dificultad para cruzar variables de distintas fuentes y la imposibilidad de detectar patrones complejos o tendencias históricas de manera automatizada. La dependencia de procesos manuales no solo incrementa la posibilidad de error humano, sino que genera una brecha entre la disponibilidad del dato y su explotación real.

Uno de los principales retos tecnológicos en este escenario es la fragmentación de la información. Los datos suelen residir en sistemas transaccionales independientes o en ficheros planos que no han sido diseñados para la consulta analítica. La ausencia de una arquitectura centralizada obliga a realizar esfuerzos de procesamiento manual que resultan ineficientes, impidiendo que las organizaciones evolucionen hacia un modelo de gestión proactivo basado en datos.

Ante esta situación, el Business Intelligence surge como la disciplina fundamental para cubrir esta brecha tecnológica. La implementación de una solución integral de BI permite estructurar un flujo de trabajo robusto que abarca todo el ciclo de vida del dato. Este proyecto se contextualiza en el diseño de una arquitectura moderna basada en tres pilares fundamentales:

- **Ingesta y Normalización (ETL):** El uso de herramientas de integración como Talend para la extracción, limpieza y unificación de formatos procedentes de fuentes heterogéneas, garantizando la calidad de la información desde su origen.
- **Almacenamiento Estructurado:** La construcción de repositorios centralizados mediante sistemas de gestión de bases de datos como MySQL, optimizados bajo modelos analíticos en estrella que aseguran la integridad y rapidez en la consulta.
- **Visualización Interactiva:** El desarrollo de capas de presentación mediante plataformas como Power BI, que permiten democratizar el acceso

a la información a través de paneles interactivos y cuadros de mando dinámicos.

En un entorno donde la transparencia y la optimización de recursos son exigencias fundamentales, la adopción de estas arquitecturas representa un valor agregado significativo. Este trabajo no solo busca demostrar la viabilidad técnica de una solución basada en herramientas líderes del mercado, sino que establece un marco de trabajo escalable para mejorar la eficiencia operativa y la planificación estratégica de la ETSISI a través del análisis avanzado de indicadores clave de desempeño.

1.2. Objetivos

El objetivo principal de este proyecto es implementar una arquitectura de Business Intelligence que permita centralizar, procesar y analizar el rendimiento académico de la ETSISI de manera estructurada. Se busca desarrollar un flujo de datos integral, desde la limpieza de fuentes heterogéneas hasta la visualización de indicadores estratégicos, proporcionando una herramienta robusta que facilite la toma de decisiones en la gestión docente.

Para alcanzar esta meta, se definen los siguientes objetivos específicos:

- Analizar y caracterizar las fuentes de datos académicas para corregir inconsistencias y asegurar la calidad de la información de origen.
- Implementar procesos ETL automatizados mediante Talend Open Studio para la integración, Transformación, normalización y carga de datos de múltiples cursos académicos.
- Diseñar y construir un Data Mart en MySQL para el almacenamiento eficiente y la consulta de registros históricos.
- Desarrollar un cuadro de mando interactivo en Power BI que visualice KPIs de rendimiento y permita identificar patrones de éxito o cuellos de botella académicos.
- Validar la integridad de los datos procesados y garantizar que la interfaz sea intuitiva para los perfiles responsables de la gestión de la escuela.

1.3. Motivación

La motivación principal de este proyecto surge de la necesidad de transformar la gestión de la información académica en la ETSISI. En un entorno donde el volumen de datos crece curso tras curso, los métodos tradicionales de análisis, basados en hojas de cálculo aisladas y procesos manuales, se han vuelto ineficientes y propensos a errores humanos.

Este Trabajo de Fin de Grado se fundamenta en tres pilares motivacionales:

- La necesidad de automatización: Actualmente, la obtención de indicadores requiere un esfuerzo considerable de recopilación y limpieza manual. Existe una clara oportunidad de aplicar técnicas de ingeniería para automatizar este flujo, liberando tiempo valioso para el análisis y la toma de decisiones.

- Valorización de los datos ocultos: Más allá de las notas finales, los sistemas de gestión almacenan información valiosa que a menudo se ignora. La motivación técnica reside en descubrir y visualizar indicadores indirectos, como la correlación entre asignaturas llave y el abandono, o la detección de patrones de rendimiento en asignaturas específicas, que no son visibles en los informes estándar.
- Aplicación de Business Intelligence en un entorno real: Este proyecto permite aplicar conocimientos avanzados de Ingeniería de Datos, Bases de Datos y Visualización para crear un producto tangible que aporte valor real a la institución, mejorando la transparencia y la calidad docente.

1.4. Estructura del documento

Para facilitar la lectura y el seguimiento técnico del proyecto, la presente memoria se ha estructurado de forma modular en seis capítulos bien diferenciados, complementados con sus respectivas referencias bibliográficas. A continuación, se detalla las secciones que estructura el documento:

- **Capítulo 1: Introducción.** Expone el contexto inicial de la propuesta, la motivación que impulsa el análisis analítico en la escuela, los objetivos generales y específicos a alcanzar.
- **Capítulo 2: Estado del arte.** Ofrece una revisión analítica de los fundamentos teóricos del Business Intelligence, la evolución de los modelos de almacenamiento de datos y las soluciones tecnológicas existentes en el ámbito de la analítica académica universitaria.
- **Capítulo 3: Desarrollo del proyecto.** Se presenta los procesos del desarrollo del proyecto, desde el Diseño hasta la arquitectura y programación de los flujos ETL en Talend, hasta el diseño y optimización del modelo dimensional en estrella.
- **Capítulo 4: Resultados.** Describe la fase de explotación y visualización en Power BI. Se presenta la estructura funcional del cuadro de mando interactivo, las páginas que lo componen (Visión General, Análisis de asignaturas y Análisis de titulaciones) y las principales métricas y hallazgos descubiertos tras el análisis de los datos históricos.
- **Capítulo 5: Conclusiones y trabajos futuros.** Recoge una valoración crítica del cumplimiento de los objetivos planteados, las lecciones técnicas aprendidas durante el despliegue de la arquitectura y las líneas de investigación propuestas para evolucionar la solución hacia la analítica predictiva.
- **Capítulo 6: Aspectos Éticos, Legales y Medioambientales.** Evalúa el impacto normativo del proyecto, poniendo especial énfasis en el cumplimiento del Reglamento General de Protección de Datos (RGPD) al tratar con registros académicos, así como la huella energética derivada de la computación y almacenamiento de los procesos.

- **Referencias bibliográficas.** Recopila de forma indexada el catálogo de fuentes, artículos científicos, documentación técnica oficial y libros utilizados para dotar de validez y rigor académico a la investigación.

Capítulo 2

Estado del arte

2.1. Evolución de los Sistemas de Apoyo a la Decisión y Business Intelligence

La gestión de la información en las organizaciones ha cambiado radicalmente en las últimas décadas. Hemos pasado de tener pocos datos a una sobreabundancia conocida como Big Data. Al principio, los sistemas se centraban solo en el procesamiento de transacciones, el llamado Online Transaction Processing o OLTP, que sirve para la operativa diaria como facturación o registros básicos. Sin embargo, en los años 90 surgió la necesidad de analizar toda esa información de forma separada, dando lugar al concepto moderno de Business Intelligence.

Según consultoras como Gartner, esta disciplina ha pasado por varias etapas. Empezó con un modelo tradicional controlado por expertos en informática que hacían informes estáticos. Después llegó el Business Intelligence de autoservicio, donde herramientas como Power BI permitieron que cualquier usuario pudiera analizar datos. Ahora estamos entrando en una fase de analítica aumentada, donde la inteligencia artificial ayuda a interpretar los resultados automáticamente. En la universidad, esto es clave para aprovechar Dark Data, que es toda esa información que se guarda pero que nunca se llega a usar para mejorar la gestión.

2.2. Integración de Datos y Evolución de los Procesos ETL

La calidad de la información constituye el pilar fundamental sobre el que se construye cualquier sistema de inteligencia de negocio. Para que un análisis sea fiable y soporte la toma de decisiones estratégicas, es imperativo implementar procesos robustos de integración de datos. Tradicionalmente, este flujo se ha articulado mediante el paradigma **ETL (Extract, Transform, Load)**, aunque la evolución tecnológica reciente ha consolidado arquitecturas alternativas como el **ELT (Extract, Load, Transform)**.

2.2.1. Perspectiva Histórica y Consolidación del ETL

El concepto de integración de datos surgió en la década de 1970 ante la necesidad de consolidar información proveniente de bases de datos heterogéneas. Sin embargo, no fue hasta la década de 1990 cuando las herramientas ETL se consolidaron como soluciones independientes.

En sus primeras implementaciones, estos procesos se caracterizaban por ser monolíticos y de ejecución local. La arquitectura clásica se basaba en la extracción de datos de sistemas transaccionales hacia un área de tránsito

denominada Staging Area. En este espacio intermedio, fuera de la base de datos de destino, los datos eran normalizados, depurados y transformados antes de ser persistidos en el almacén de datos definitivo.

Durante esta era, el procesamiento se realizaba mayoritariamente por lotes (**batch processing**) durante ventanas de mantenimiento nocturnas. Si bien este modelo garantizaba un control exhaustivo de la integridad del dato, presentaba limitaciones críticas en términos de escalabilidad y flexibilidad frente al crecimiento exponencial del volumen de información.

2.2.2. La Revolución Cloud y el Cambio hacia el ELT

A partir de 2010, la irrupción de las infraestructuras en la nube y el auge del Big Data transformaron los paradigmas de integración. La aparición de almacenes de datos en la nube de alto rendimiento (como Snowflake, Google BigQuery o Amazon Redshift) permitió desplazar la carga de procesamiento al sistema de destino.

Este cambio propició la aparición del modelo ELT:

- **ETL (Extract, Transform, Load):** La transformación ocurre en un servidor intermedio o motor de integración antes de la carga. Garantiza que solo los datos limpios y transformados lleguen al destino.
- **ELT (Extract, Load, Transform):** Los datos se cargan en bruto en el Data Warehouse y se transforman a posteriori aprovechando la potencia de cálculo elástica de la nube.




Figura 1: Diseño del proceso ETL.

Tras evaluar ambos paradigmas, **en este proyecto se ha optado por la implementación de una arquitectura basada estrictamente en el modelo ETL**. Esta decisión responde a la necesidad de garantizar la máxima integridad del dato antes de su persistencia en el repositorio final.

A diferencia de un enfoque ELT, donde la limpieza se posterga, el uso de ETL en este proyecto permite establecer un Quality Gate mediante el motor de integración de Talend. Esto asegura que solo los registros que cumplen con las reglas de negocio académicas, como la ausencia de nulos críticos o la normalización de identificadores de asignaturas sean procesados.

2.3. Modelado Dimensional: El Esquema en Estrella

A diferencia de los sistemas transaccionales (*OLTP - Online Transactional Processing*), optimizados para la inserción y actualización rápida de registros, el análisis de datos requiere un enfoque orientado a la consulta masiva y la agregación de información, conocido como modelado dimensional (*OLAP - Online Analytical Processing*). El diseño más extendido y eficiente en este ámbito es el **esquema en estrella** (*Star Schema*).

Esta arquitectura organiza la información en una estructura radial donde una tabla central se conecta directamente con diversas tablas periféricas, clasificando los datos en dos categorías fundamentales:

- **Tablas de Hechos:** Constituyen el núcleo del modelo y almacenan las métricas cuantitativas o indicadores de rendimiento de un proceso de negocio o académico. Cada registro en esta tabla representa un evento específico, como una matriculación o la obtención de una calificación final. Se caracterizan por contener claves foráneas que apuntan a las dimensiones y datos numéricos aditivos que permiten cálculos estadísticos (sumas, promedios, ratios).
- **Tablas de Dimensiones:** Son tablas descriptivas que rodean a la tabla de hechos y proporcionan el contexto necesario para el análisis. Contienen atributos cualitativos que permiten filtrar y segmentar los datos, como los datos sociodemográficos del alumno, los detalles de la asignatura, el desglose del curso académico o el departamento docente. A diferencia de las bases de datos tradicionales, estas tablas suelen estar desnormalizadas para favorecer la legibilidad y el rendimiento.

2.3.1. Ventajas del Modelado Dimensional en Proyectos de Business Intelligence

La adopción de esquemas en estrella en proyectos de inteligencia de negocio no responde a una preferencia estética, sino a beneficios técnicos fundamentales para la arquitectura de datos moderna:

1. **Eficiencia en el Rendimiento de Consulta:** Al reducir el número de uniones necesarias para recuperar información, el motor de la base de datos puede ejecutar las consultas con una latencia mínima. Esta estructura plana es especialmente crítica cuando se manejan millones de registros, donde cada relación adicional penalizaría exponencialmente el tiempo de respuesta.
2. **Predictibilidad en el Comportamiento Analítico:** Herramientas de visualización líderes como Power BI o Tableau están optimizadas para trabajar sobre esquemas en estrella. Este modelo garantiza que el filtrado y la propagación de datos sean unívocos, evitando errores comunes en el cálculo de métricas complejas (como las expresiones DAX que suelen ocurrir en modelos excesivamente normalizados).

3. **Usabilidad para el Usuario Final:** La separación clara entre "lo que se mide" (hechos) y cómo se filtra" (dimensiones) hace que el modelo semántico sea intuitivo. Esto permite que los analistas y gestores puedan realizar descubrimientos de datos de forma autónoma Self-Service BI sin necesidad de comprender la complejidad técnica del origen de los datos.
4. **Mantenibilidad y Escalabilidad:** Al ser una estructura modular, añadir nuevas dimensiones o métricas no requiere una reestructuración del modelo existente, permitiendo que la solución crezca orgánicamente a medida que evolucionan las necesidades de información de la institución o empresa.




Figura 2: Ejemplo de un modelo estrella.

2.4. Visualización de Datos y Dashboards Interactivos

La visualización de datos ha trascendido su concepción tradicional como una mera representación gráfica de resultados para consolidarse como una disciplina estratégica dentro de la inteligencia de negocio. Su objetivo primordial no es la ornamentación estética, sino la reducción de la carga cognitiva del analista, permitiendo identificar patrones, tendencias y anomalías que permanecerían ocultos en estructuras tabulares complejas.

2.4.1. Evolución hacia el Business Intelligence de Autoservicio

La industria ha experimentado una transición significativa desde los informes estáticos y preconfigurados hacia plataformas dinámicas de Self-Service BI. Herramientas líderes en el sector, como **Power BI**, **Tableau** y **Qlik**, han democratizado el acceso al análisis de datos, permitiendo a perfiles no técnicos explorar la información de manera intuitiva.

Lo que distingue a las soluciones modernas es su capacidad de integración y procesamiento avanzado:

- **Conectividad Multifuente:** Capacidad de unificar datos provenientes de data warehouses, servicios en la nube (SaaS) y archivos locales en un único modelo semántico.
- **Analítica Aumentada:** Incorporación de algoritmos de Inteligencia Artificial que sugieren visualizaciones automáticamente e identifican impulsores clave detrás de los datos.
- **Interacción mediante Lenguaje Natural:** Funcionalidades como Q&A (Question and Answer) de Power BI, que permiten al usuario realizar consultas complejas utilizando lenguaje cotidiano para obtener respuestas visuales instantáneas.

2.4.2. Técnicas de Análisis Visual en el Ámbito Académico

En el contexto de la educación superior, donde la toma de decisiones impacta directamente en la calidad docente y el éxito del alumnado, la visualización se convierte en una herramienta diagnóstica de primer orden. Se identifican dos técnicas fundamentales de amplia adopción:

- **Mapas de Calor (Heatmaps):** Esta técnica de densificación cromática permite proyectar el rendimiento sobre matrices de tiempo o asignaturas. En el ámbito académico, resultan esenciales para detectar instantáneamente "puntos calientes" de fracaso escolar o periodos críticos en el calendario lectivo donde el rendimiento decae, facilitando la implementación de medidas de refuerzo preventivas.
- **Narrativa de Datos (Data Storytelling):** Este enfoque transforma el dashboard en un hilo conductor lógico que guía al usuario desde la visión macroscópica hasta el detalle micro. Partiendo de indicadores clave de desempeño globales, como la tasa de eficiencia o de abandono, el sistema permite realizar un drill down (profundización) para analizar cohortes específicas, comparar el desempeño de alumnos según su vía de acceso o evaluar la evolución de una asignatura a lo largo de varios ciclos académicos.

Esta capacidad de navegación interactiva permite que los datos dejen de ser registros estáticos para convertirse en una narrativa coherente sobre el progreso educativo, facilitando una gestión basada en la evidencia.

2.5. Casos de Uso de Inteligencia de Negocio en el Ámbito Académico

La educación superior ha evolucionado hacia un modelo de gestión basado en datos, donde la capacidad de integrar información de sistemas de gestión académica y entornos virtuales de aprendizaje es crítica para el éxito institucional.

2.5.1. Georgia Institute of Technology

Esta institución, referente mundial en ingeniería, implementó una infraestructura de datos masiva para mejorar sus tasas de graduación. Utilizando procesos ETL para consolidar décadas de registros académicos y datos de interacción en tiempo real de sus plataformas digitales, lograron desarrollar un sistema de alertas tempranas.

- **Tecnología:** Arquitectura basada en **Data Lakes** y herramientas de visualización para coordinadores de grado.
- **Resultados:** El sistema permite identificar estudiantes en riesgo de abandono con semanas de antelación, contribuyendo a un incremento del 20 % en la tasa de graduación en la última década gracias a intervenciones proactivas.

2.5.2. Arizona State University

ASU es reconocida como una de las universidades más innovadoras de Estados Unidos debido a su uso intensivo de la analítica. Desarrollaron el sistema *e-Advisor*, que integra flujos de datos mediante procesos ETL que se actualizan diariamente para monitorizar el progreso de cada estudiante frente a su plan de estudios.

- **Tecnología:** Integración de sistemas *Salesforce* y *Workday* con motores analíticos de BI.
- **Resultados:** La tasa de retención de alumnos de primer año alcanzó el 90 %, y la universidad logró escalar su oferta académica sin comprometer la atención personalizada, gracias a que los gestores disponen de *dashboards* actualizados sobre el rendimiento por asignatura y facultad.

2.5.3. Universidad de Murcia

En el contexto español, la Universidad de Murcia ha destacado por su proyecto de Universidad Digital. Han implementado un almacén de datos corporativo que unifica la información administrativa, docente y de investigación, facilitando la transparencia y la toma de decisiones estratégicas.

- **Tecnología:** Procesos ETL para la extracción de bases de datos relacionales locales y visualización mediante cuadros de mando corporativos.
- **Resultados:** Automatización total de los informes de calidad requeridos por agencias evaluadoras (como ANECA), reduciendo en un 60 % el tiempo dedicado a la recolección de indicadores y permitiendo a los decanos visualizar en tiempo real el equilibrio entre oferta de plazas y demanda de matrícula.

2.5.4. Tendencias Comunes en el Sector Educativo

Al analizar los casos de éxito en instituciones de educación superior, se observan patrones tecnológicos y estratégicos comunes:

1. **Interoperabilidad de Sistemas:** La necesidad de romper los silos de información uniendo los datos de matriculación con los datos de actividad en campus virtuales.
2. **Transición de la Analítica Descriptiva a la Predictiva:** El uso del dato no solo para informar sobre lo que pasó el curso anterior, sino para predecir comportamientos futuros del alumnado.
3. **Enfoque en el *Learning Analytics*:** El uso de visualizaciones específicas para que los docentes puedan ajustar sus metodologías según el rendimiento real observado en los paneles de control.
4. **Democratización del Dato Académico:** Proporcionar acceso a la información no solo a la alta dirección, sino también a coordinadores de asignatura y tutores.

Estos ejemplos demuestran que la implementación de arquitecturas ETL y modelos dimensionales en la universidad permite pasar de una gestión reactiva a una estrategia proactiva, garantizando la sostenibilidad y la excelencia académica en un entorno cada vez más competitivo.

2.6. Marco Tecnológico

Para el desarrollo de este proyecto se han seleccionado herramientas que representan el estándar actual en el sector del análisis de datos. A continuación, se detallan las tecnologías utilizadas, su definición técnica y la función que cumplen dentro del sistema:

2.6.1. Microsoft Excel y CSV

Microsoft Excel es una aplicación de hojas de cálculo que permite manipular datos numéricos y alfanuméricos en tablas, mientras que el formato CSV es un estándar de archivos de texto plano que almacena información separada por comas. En este trabajo, ambos han actuado como la fuente de datos original, ya que es el formato en el que los sistemas de gestión de la universidad exportan la información académica. Se han utilizado para realizar una inspección rápida de los datos en bruto antes de iniciar el procesamiento automatizado.



Figura 3: Excel.

2.6.2. Talend Open Studio

Es una herramienta de integración de datos de código abierto basada en el ecosistema Java que permite diseñar flujos de trabajo mediante una interfaz gráfica. Se ha empleado como el motor principal de ETL para extraer la información de los archivos originales y transformarla. Su uso ha sido fundamental para automatizar tareas críticas como la eliminación de registros duplicados, la gestión de valores nulos y la normalización de formatos de fecha, asegurando que la información sea consistente.



Figura 4: Talend.

2.6.3. MySQL

Se trata de un sistema de gestión de bases de datos relacionales basado en lenguaje SQL, conocido por su estabilidad y rendimiento. En este proyecto, MySQL funciona como el repositorio centralizado o Data Mart donde se almacena la información ya procesada y limpia. Su función es permitir consultas rápidas y seguras, organizando los datos de los siete cursos académicos bajo un modelo estructurado que facilita el análisis posterior sin afectar el rendimiento del sistema.



Figura 5: MySQL.

2.6.4. Microsoft Power BI

Es una plataforma de inteligencia de negocios y visualización que permite conectar diversas fuentes de datos para transformarlos en paneles interactivos. Se ha utilizado para construir la capa visual del proyecto, concretamente el cuadro de mando final. Gracias a su motor de cálculo y al lenguaje de fórmulas DAX, se han programado indicadores específicos para medir el rendimiento académico y crear comparativas entre cursos, ofreciendo una interfaz intuitiva para el usuario.



Figura 6: PowerBI.

2.6.5. Git y GitHub

Git es un sistema de control de versiones distribuido que permite rastrear cualquier cambio en el código fuente, mientras que GitHub es la plataforma en la nube que aloja estos repositorios. En este TFG, se han utilizado para gestionar la trazabilidad del desarrollo, manteniendo una copia de seguridad constante de los flujos de Talend y de las fórmulas de Power BI. Su uso garantiza que el proyecto siga las buenas prácticas de ingeniería, permitiendo recuperar versiones anteriores ante cualquier error.



Figura 7: GitHub.

Capítulo 3

Desarrollo del proyecto

3.1. Diseño del proyecto

3.1.1. Arquitectura

La arquitectura propuesta para este proyecto implementa un ecosistema de Inteligencia de Negocio diseñado para transformar datos académicos heterogéneos en insights estratégicos. A diferencia de los modelos tradicionales de informes estáticos, esta solución articula un flujo de ingeniería de datos robusto que garantiza la integridad y calidad de la información antes de su explotación.

Siguiendo el esquema visual de la Figura 8, el sistema se estructura en cuatro bloques funcionales principales:

1. **Adquisición y Control:** Captura de registros académicos en formato plano y gestión de versiones.
2. **Transformación:** Limpieza, normalización y aplicación de lógica de negocio.
3. **Almacenamiento y Validación:** Persistencia y validación de datos depurados en un repositorio relacional.
4. **Visualización:** Modelado dimensional y presentación interactiva de indicadores.




Figura 8: Arquitectura ETL del proyecto

3.1.2. Componentes Principales

3.1.2.1. Origen de Datos y Control de Versión

El sistema se nutre de archivos **Excel** que contienen los registros históricos del rendimiento académico de la ETSISI. La arquitectura se integra con **GitHub** como sistema de control de versiones centralizado, actuando como el repositorio principal para la gestión de la totalidad de los artefactos lógicos desarrollados durante el ciclo de vida del proyecto. Esta implementación no se limita únicamente a los flujos de transformación, sino que abarca todos los componentes de código que definen el comportamiento del sistema.

3.1.2.2. Motor de Transformación

Talend constituye el núcleo operativo de la fase ETL. Actúa como el puente entre el dato bruto y el dato refinado, permitiendo:

- **Integración de fuentes:** Consolidación y unificación de múltiples archivos de datos históricos correspondientes a diferentes cursos académicos en un único flujo de trabajo homogéneo.
- **Mapeo y transformación:** Procesamiento avanzado de los registros mediante reglas lógicas para el filtrado, estandarización de cadenas de texto y enriquecimiento de las variables de origen.
- **Garantía de unicidad:** Detección y depuración de registros redundantes o duplicados para asegurar la consistencia de la información antes de su almacenamiento definitivo.

3.1.2.3. Plataforma de Almacenamiento: MySQL

MySQL funciona como el repositorio central de datos transformados. A diferencia de un entorno transaccional puro, en esta arquitectura MySQL cumple dos funciones críticas:

- **Persistencia de Datos Limpios:** Almacena exclusivamente los 5.047 registros validados por el proceso ETL.
- **Capa de Auditoría:** Permite ejecutar consultas de validación post-carga para asegurar que la tasa de registros erróneos en el destino sea del 0 %.

3.1.2.4. Capa de Visualización y Modelado: Power BI

Power BI completa la arquitectura como la interfaz de explotación. Es fundamental destacar que es en este componente donde reside la lógica del **Modelo Dimensional (Esquema en Estrella)**.

- **Dashboards interactivos:** Permite una exploración dinámica de la información académica mediante el uso de filtros.
- **Creación de nuevas métricas:** Permite el diseño y programación de indicadores avanzados y métricas calculadas dinámicamente mediante el lenguaje DAX. Esto facilita la obtención de ratios complejos que se recalculan en tiempo real en función del contexto de filtro seleccionado por el usuario, aportando un análisis mucho más profundo que los datos estáticos de origen.

3.2. Diseño de la transformación por capas

Para diseñar la solución de este proyecto, he optado por un diseño de BI clásico dividido en capas lógicas. Esta separación permite que el sistema sea modular, escalable y mucho más fácil de mantener, ya que cada fase tiene una responsabilidad única y no interfiere con el resto.

A nivel general, el flujo de datos avanza desde su estado más bruto hasta convertirse en información interactiva, pasando por las siguientes cuatro capas principales y una transversal:

3.2.1. Capa de Origen de Datos

Esta es la base de la arquitectura, donde reside la información original del sistema. En mi caso, está formada por archivos en formato Excel y CSV que contienen los registros académicos. Sin embargo, con el objetivo de mejorar la consistencia y la disponibilidad de los datos, estos han sido gestionados y almacenados como metadatos en Talend, lo que facilita su extracción y procesamiento posterior.

Esta capa es estática, es decir, los datos almacenados en ella no se modifican en ningún momento. Su función principal es servir como punto de partida o Raw Data, proporcionando la fuente original desde la cual se alimentan el resto de las capas del sistema.

3.2.2. Capa de Integración y Procesamiento

Aquí es donde ocurre la limpieza de datos. He utilizado Talend para construir esta capa intermedia. Su función es extraer los datos de la capa de origen, transformarlos (limpiando nulos, quitando registros duplicados, etc...) y cargarlos en la base de datos. Al tener esto en una capa separada, si el día de mañana cambian el formato de los Excel originales, solo habría que tocar esta parte del proyecto sin que afecte a los paneles finales.

3.2.3. Capa de Almacenamiento Relacional

Para la persistencia de los datos ya procesados, se ha optado por una base de datos en MySQL. En esta capa, la información se almacena en tablas relacionales que garantizan la integridad de los datos mediante restricciones y validaciones definidas en las consultas y el propio esquema de la base de datos.

MySQL actúa como un almacén intermedio seguro y eficiente, centralizando todos los registros académicos en un único punto de acceso. Esto facilita su posterior explotación en PowerBI, permitiendo consultas optimizadas y un acceso estructurado a la información.

3.2.4. Capa de Modelado Dimensional y Visualización

Esta es la capa más crítica del proyecto, implementada íntegramente en Microsoft Power BI. A diferencia de un modelo relacional tradicional, aquí es donde he diseñado el **Modelo de Estrella**.

He configurado las relaciones entre la tabla de hecho y las tablas de dimensiones directamente en el motor de Power BI. Además, en esta capa es donde he programado la lógica de negocio mediante medidas DAX para calcular los indicadores indirectos y he diseñado la interfaz interactiva para el usuario final.

3.3. Implementación del proceso ETL

En esta fase del proyecto se detalla la construcción de la lógica de datos, desde la configuración del entorno hasta el despliegue de los flujos finales. El objetivo es transformar los datos académicos en bruto en información estructurada y lista para el análisis.

3.3.1. Configuración Inicial

Antes de abordar el desarrollo lógico del sistema, resulta imprescindible establecer un entorno de trabajo local sólido y estructurado. El objetivo principal es garantizar que los distintos componentes del proyecto puedan comunicarse entre sí sin conflictos, sentando una base estable para la posterior extracción, integración y visualización de los datos académicos.

3.3.1.1. Creación del proyecto en Talend

El primer paso consistió en la inicialización del entorno de trabajo en Talend Open Studio. Al ejecutar la herramienta por primera vez, se procedió a realizar las siguientes acciones:

1. **Configuración de conexión:** Se estableció una conexión de tipo local para almacenar todos los archivos y metadatos directamente en el equipo de desarrollo.
2. **Inicialización del proyecto:** Se creó un nuevo proyecto denominado **TALEND_BACK**. Este actúa como el contenedor centralizado donde se organiza todo el desarrollo del sistema ETL.
3. **Verificación del repositorio:** Se accedió a la interfaz principal para validar la estructura del repositorio generado. En este espacio se organizarán los futuros flujos de integración (Job Designs) y las definiciones de conexiones a bases de datos (Metadata).




Figura 9: creación de un nuevo proyecto local en Talend




Figura 10: Interfaz principal de Talend y vista del repositorio de proyecto

3.3.1.2. Creación y configuración de la base de datos en MySQL

Una vez configurado el entorno de integración, el siguiente paso consistió en preparar el repositorio de destino. Este repositorio actuará como el Data Mart donde Talend volcará la información una vez limpia y transformada, permitiendo que posteriormente Power BI pueda consumirla de forma eficiente.

El proceso de configuración en el gestor relacional MySQL se dividió en las siguientes fases:

1. **Configuración de la conexión:** Se estableció una conexión estándar (TCP/IP) con el servidor MySQL local. Para ello, se configuró el host en la dirección de bucle local 127.0.0.1 a través del puerto 3306, utilizando las credenciales del usuario administrador (root). Esta conexión se etiquetó como **Datamart** para identificar rápidamente su propósito dentro del flujo de trabajo.




Figura 11: Configuración de la conexión local a MySQL

2. **Definición del esquema y tablas:** Con la conexión establecida, se procedió a crear la estructura lógica de almacenamiento mediante sentencias SQL. Se ejecutó el comando para inicializar la base de datos y, posteriormente, se definió la tabla destino:

- `CREATE DATABASE rendimiento_transformado;`
- `CREATE TABLE rendimiento_unico;`




Figura 12: Sentencias de creación de la base de datos y la tabla destino

Con este paso, la base de datos queda operativa y a la espera de recibir el flujo de datos procesados desde la herramienta de ETL.

3.3.1.3. Control de versiones con Git y GitHub

Para garantizar la trazabilidad del desarrollo, facilitar la recuperación ante posibles errores y mantener una copia de seguridad centralizada, he

implementado un sistema de control de versiones. La configuración de este entorno se ha realizado siguiendo tres pasos fundamentales:

1. **Inicialización del repositorio local:** A través de la consola de comandos Git Bash, navegué hasta el directorio raíz del proyecto y ejecuté el comando `git init`. Con esta instrucción, la carpeta del TFG se transformó en un repositorio local capaz de rastrear todos los cambios realizados en los archivos.




Figura 13: Inicialización del repositorio local mediante línea de comandos.

2. **Creación del repositorio remoto:** El siguiente paso consistió en acceder a la plataforma web de GitHub para crear un nuevo repositorio vacío. Aquí definí el nombre del proyecto y establecí la visibilidad como privada para proteger la integridad de los datos académicos.




Figura 14: Configuración del repositorio remoto en la plataforma GitHub.

3. **Sincronización y subida (Push):** Tras definir un archivo `.gitignore` para excluir ficheros temporales y archivos pesados innecesarios, vinculé ambos repositorios y subí los archivos definitivos. Finalmente, comprobé en la interfaz web que elementos clave como el entorno de Talend y el archivo de Power BI (TFG.pbix) se habían sincronizado correctamente.




Figura 15: Verificación de los archivos sincronizados en el repositorio remoto.

Con esta estructura, el proyecto queda totalmente respaldado en la nube, permitiendo una gestión del desarrollo mucho más segura y profesional.

3.3.2. Carga de datos crudos

Una vez finalizada la configuración del entorno, el siguiente paso crítico es la ingesta de los datos brutos. En lugar de configurar estas conexiones manualmente en cada proceso (Job), he centralizado la definición de los archivos en la sección **Metadata** del repositorio de Talend. Esta práctica no solo optimiza el tiempo de desarrollo, sino que garantiza la consistencia de los datos y facilita su reutilización en todo el proyecto.




Figura 16: Sección de metadata en el repositorio de Talend

Dado que los datos proporcionados por la ETSISI se encuentran en formato de texto plano, se procedió a crear una nueva conexión de tipo **File delimited**. En los dos primeros pasos se escribe el nombre y seleccionar el fichero que quieres cargar.

Figura 17: Panel del paso 1 de configuración del componente de lectura CSV.

Figura 18: Panel del paso 2 de configuración del componente de lectura CSV.

A continuación procedemos el tercer paso que es el más complicado donde configuraron los siguientes parámetros técnicos fundamentales:

1. **Separador de campos (Field Separator):** Se estableció la coma (,) como delimitador. Al tratarse de archivos CSV, este carácter indica al motor de Talend dónde termina una columna y comienza la siguiente.
2. **Fila de encabezado (Header):** Se activó la opción **Set heading row as column names**. Esto instruye a la herramienta para que ignore la primera fila como dato real y la interprete como los nombres de los atributos, evitando errores de tipo de dato al procesar registros numéricos.

3. **Codificación (Encoding):** Se seleccionó la codificación UTF-8 para garantizar la correcta lectura de caracteres especiales como tildes y la letra "ñ", esenciales en el contexto académico español.
4. **Separador de filas (Row Separator):** Se mantuvo el salto de línea estándar (\n), que define el final del registro de un alumno y el inicio del siguiente.
5. **Delimitador de texto (Text Enclosure):** Se configuró el uso de comillas dobles ("). Este parámetro evita que comas contenidas dentro de un texto se interpreten erróneamente como saltos de columna.
6. **Carácter de escape (Escape Char):** Se definió para manejar casos donde el propio texto contiene comillas, permitiendo que el motor lea el carácter como parte del dato.
7. **Formatos numéricos (Advanced Settings):** Se adaptaron los separadores al estándar español, configurando el punto (.) como separador de miles y la coma (,) como separador decimal. Esto permite que las calificaciones se conviertan correctamente a tipos Float o Double.




Figura 19: Panel del paso 3 de configuración del componente de lectura CSV.

Con esta configuración, Talend es capaz de interpretar correctamente la estructura de los archivos originales, permitiendo iniciar las transformaciones lógicas necesarias.




Figura 20: Carga de datos crudos finalizada

3.3.3. Unificación de los datos crudos

Para resolver la fragmentación de la información proveniente de distintos ficheros anuales, se empleó el componente tUnite. Su única función en el flujo de trabajo es anexar los múltiples conjuntos de datos de entrada en un único flujo unificado. De esta forma, todas las transformaciones posteriores y la carga final en la base de datos se realizan sobre una sola tabla consolidada, simplificando enormemente el diseño del proceso ETL.




Figura 21: Unificación de datos mediante el componente tUnite.

3.4. Transformación de la tabla unificada

Una vez extraídos y unificados los datos de origen, el flujo de datos entra en la fase central del proceso ETL: la transformación. Esta fase se ha estructurado en tres grandes etapas: filtro y selección, enriquecimiento y estandarización.

3.4.1. Filtro y selección de datos

El primer paso aplicado sobre la tabla unificada consistió en el filtrado de registros y la selección de los campos verdaderamente útiles para el modelo analítico, descartando la información redundante que sobrecargaba el sistema.

Al analizar la estructura de los ficheros originales, se identificó que las columnas como aprobados, rendimiento y matriculados en primera, segunda y tercera matrícula no eran necesarias. La justificación técnica para su eliminación es doble:

1. **Redundancia:** Si una fila de datos corresponde a un grupo en primera matrícula, las columnas destinadas a la segunda y tercera matrícula se quedaban vacías (generando valores nulos innecesarios).
2. **Optimización del modelo:** Esa misma información ya viene recogida de forma mucho más eficiente y estructurada en columnas generales del origen, como n_matricula y n_matriculados. Mantener ambas estructuras solo duplicaría el tamaño de la base de datos sin aportar valor analítico.

A nivel técnico, esta criba se realizó a través del componente de mapeo principal (tMap). Por un lado, las columnas descartadas simplemente no se mapearon hacia el flujo de salida. Por otro lado, las condiciones lógicas para filtrar las filas se configuraron en el recuadro de expresiones habilitado justo debajo de la tabla de salida (denominada por defecto output1). De este modo, el componente solo deja pasar a la siguiente fase las columnas seleccionadas y las filas que cumplen los criterios establecidos.

Column
_Plan_de_estudios
Nivel_de_Estudios
Tipo_Especial
Ano_Academico
Numero_de_Matriculas
N_Matriculados
N_Aprobados
Rendimiento
Aprobados_en_1_Mat
Matriculados_por_1_vez
Rendimiento_en_1_Mat
Aprobados_en_2_Mat
Matriculados_por_2_vez
Rendimiento_en_2_Mat
Aprobados_en_3_Mat
Matriculados_por_3_vez_o_mas
Rendimiento_en_3_Mat
Eficiencia_en_matricula
Codigo_Centro
Asignatura
Tipo_Asignatura
Curso
Tipo_Convalidacion

Figura 22: Tabla inicial.

Expression	Column
row3._Plan_de_estudios	_Plan_de_estudios
row3.Nivel_de_Estudios	Nivel_de_Estudios
row3.Tipo_Especial	Tipo_Especial
row3.Ano_Academico	Ano_Academico
row3.Numero_de_Matriculas	Numero_de_Matriculas
row3.N_Matriculados	N_Matriculados
row3.N_Aprobados	N_Aprobados
row3.Rendimiento	Rendimiento
row3.Eficiencia_en_matricula	Eficiencia_en_matricula
row3.Codigo_Centro	Codigo_Centro
row3.Asignatura	Asignatura
row3.Tipo_Asignatura	Tipo_Asignatura
row3.Curso	Curso
row3.Tipo_Convalidacion	Tipo_Convalidacion

Figura 23: Tabla filtrado y seleccionado.

3.4.2. Enriquecimiento

La segunda etapa dentro de la fase de transformación consistió en el enriquecimiento del conjunto de datos. Esta técnica de ingeniería de datos se basa en generar nueva información de valor analítico a partir de los registros ya existentes, con el objetivo de optimizar el modelo y facilitar los cálculos posteriores en el cuadro de mando.

En concreto, mediante el componente de mapeo (tMap), se añadieron dos columnas calculadas al flujo de salida:

1. **Generación de clave única (id_unico_powerbi):** En el modelado dimensional para Business Intelligence, establecer relaciones entre tablas utilizando claves compuestas consume muchos recursos y ralentiza el motor analítico. Para solucionar este problema, se creó esta nueva columna que actúa como clave primaria o subrogada. Mediante la concatenación de los campos identificadores del registro, se generó un identificador único para cada fila, lo que optimizará drásticamente el rendimiento de las relaciones en Power BI. Además, la creación de este identificador único permite verificar la existencia de duplicados en la clave; utilizando el componente tUniqueRow sobre esta columna, se puede asegurar la integridad de los

datos al identificar y filtrar registros repetidos antes de la carga final. La clave única es creada con el código siguiente:

```

row3.Anio_Academico + "_" +
row3._Plan_de_estudios + "_" +
row3.Asignatura.replaceAll("\\s+", " ").trim() + "_" +
row3.Numero_de_Matriculas + "_" +
row3.Curso

```

2. **Creación de la variable dicotómica (es_nuevo):** Se introdujo un nuevo campo numérico para clasificar la tipología del alumnado. A través de una expresión condicional, el sistema evalúa el registro y le asigna el valor 1 si el grupo corresponde a alumnos de nuevo ingreso, y el valor 0 si se trata de alumnos repetidores. Transformar esta condición en un valor binario (booleano) es una mejora táctica crucial, ya que permitirá programar medidas DAX mucho más sencillas y eficientes a la hora de comparar las tasas de rendimiento entre ambos perfiles de estudiantes. Para la creación de este campo, hemos hecho lo siguiente:

```

row3.Numero_de_Matriculas == 1 ? 1 : 0

```

Expression	Column
row3._Plan_de_estudios	_Plan_de_estudios
row3.Nivel_de_Estudios	Nivel_de_Estudios
row3.Tipo_Especial	Tipo_Especial
row3.Ano_Academico	Ano_Academico
row3.Numero_de_Matriculas	Numero_de_Matriculas
row3.N_Matriculados	N_Matriculados
row3.N_Aprobados	N_Aprobados
row3.Rendimiento	Rendimiento
row3.Eficiencia_en_matricula	Eficiencia_en_matricula
row3.Codigo_Centro	Codigo_Centro
row3.Asignatura	Asignatura
row3.Tipo_Asignatura	Tipo_Asignatura
row3.Curso	Curso
row3.Tipo_Convalidacion	Tipo_Convalidacion
row3.Ano_Academico + "_" + row3._Plan_de_estudios + "_" + ...	ID_Unico_PowerBI
row3.Numero_de_Matriculas == 1 ? 1 : 0	Es_Nuevo

Figura 24: Tabla unificada después del enriquecimiento

Con la adición de dos campos nuevos y la separación del código y nombre en la asignatura y plan de estudio, el conjunto de datos queda completamente estandarizado y enriquecido.

3.4.3. Estandarización

La falta de consistencia en el formato de los textos (como la coexistencia de “ADMINISTRACION” y “ADMINISTRACIÓN”) es una de las principales fuentes de error y duplicación en los datos. Para asegurar la calidad de la información, esta fase del proceso ETL se encarga de unificar y homogeneizar los registros. A continuación, se describen los mecanismos de normalización de caja y supresión de tildes aplicados en Talend para consolidar un formato único y comparable en la base de datos de destino:

1. **Separación de códigos y nombres (Asignatura y Plan de Estudios):** Se procedió a la división y aislamiento de los códigos identificadores respecto a sus nombres descriptivos, tanto para las

asignaturas como para los planes de estudio. Esta segmentación es una práctica de diseño de datos esencial que persigue un doble objetivo. En primer lugar, facilita enormemente la posterior presentación de los datos en la capa de informe, permitiendo que las visualizaciones y gráficos muestren etiquetas limpias, claras y legibles sin arrastrar códigos alfanuméricos densos. En segundo lugar, constituye el paso habilitador fundamental para la creación del modelo en estrella en Power BI; al separar los componentes de identidad (códigos) de los componentes descriptivos (nombres), se facilita la estructuración de las tablas de dimensiones, permitiendo que actúen de forma independiente a la tabla de hechos central. En este apartado, hemos hecho los mismos pasos en los dos campos, ya que los datos tienen la misma estructura, así que solo mostramos el código del campo plan de estudio como un ejemplo:

```
TalendString.removeAccents(
row3._Plan_de_estudios.split(" - ")[1].trim()
).toUpperCase()

row3._Plan_de_estudios.split(" - ")[0].trim()
```

2. **Filtrado de registros con valor nulo o vacío:** Por otro lado, en este mismo componente se aplicaron filtros a nivel de registro, centrándose específicamente en los campos que conforman la clave compuesta de la tabla destino (Curso, Número de matrícula, asignatura, año académico y el plan de estudios).

La justificación de este filtrado radica en la integridad de los datos. Para que un registro sea válido y pueda insertarse correctamente en la base de datos MySQL sin generar errores de clave primaria, todos los campos que forman su clave compuesta deben estar completos. Si un registro extraído del sistema de la universidad presentaba valores nulos, celdas vacías o formatos anómalos en estos campos identificadores, se consideraba un registro corrupto.

Para limpiar estas anomalías, en el mismo recuadro de expresiones de la tabla de salida (output1), se programaron las condiciones lógicas pertinentes. De este modo, el componente evalúa cada fila en tiempo de ejecución y bloquea el paso de cualquier registro cuya clave identificativa esté incompleta, garantizando que solo la información estructurada y válida avance hacia la base de datos final.

```
// 1. Validar el Año
row3.Año_Academico != null && row3.Año_Academico.trim().length() > 0 &&
// 2. Validar el Plan
row3._Plan_de_estudios != null && row3._Plan_de_estudios.trim().length() > 0 &&
// 3. Validar la Asignatura
row3.Asignatura != null && row3.Asignatura.trim().length() > 0 &&
// 4. Validar el N° de Matrícula
row3.Numero_de_Matriculas != null && row3.Numero_de_Matriculas > 0 &&
// 5. Validar el N° de Curso
row3.Curso != null && row3.Curso > 0
```

Figura 25: Filtro de las claves primarias

output1	
<pre>// 1. Validar el Año row3.Ano_Academico != null && row3.Ano_Academico.trim().length() > 0 &&</pre>	
Expression	Column
TalendString.removeAccents(... row3._Plan_de_estudios.spli...	Nombre_Plan_de_Estudios
row3.Nivel_de_Estudios	Nivel_de_Estudios
row3.Tipo_Especial	Tipo_Especial
row3.Ano_Academico	Anio_Academico
row3.Numero_de_Matriculas	Numero_de_Matriculas
row3.N_Matriculados	N_Matriculados
row3.N_Aprobados	N_Aprobados
row3.Rendimiento	Rendimiento
row3._Plan_de_estudios.split(" ")[0].trim()	Codigo_Plan_de_Estudios
row3.Eficiencia_en_matricula	Eficiencia_en_matricula
row3.Codigo_Centro	Codigo_Centro
TalendString.removeAccents(... row3.Asignatura.split(" ")[1]...	Nombre_Asignatura
row3.Asignatura.split(" ")[0].trim()	Codigo_Asignatura
row3.Tipo_Asignatura	Tipo_Asignatura
row3.Curso	Curso
row3.Tipo_Convalidacion	Tipo_Convalidacion
row3.Ano_Academico + "." + row3._Plan_de_estudios + "." + ...	ID_Unico_PowerBI
row3.Numero_de_Matriculas == 1 ? 1 : 0	Es_Nuevo

Figura 26: Tabla unificada después de la estandarización

3. **Control de unicidad mediante tUniqueRow:** Finalmente, se incorporó el componente **tUniqueRow** con el propósito de auditar y validar de forma estricta la unicidad de los registros procesados en el flujo inmediato anterior. La implementación de esta regla de calidad de datos se aplicó específicamente sobre la columna **ID_Unico_PowerBI**. Al configurar este componente como un filtro de exclusión, el sistema es capaz de interceptar de manera proactiva cualquier fila redundante, garantizando que cada registro transferido hacia el repositorio final posea una clave primaria genuinamente unívoca. Este control resulta crítico para mitigar el riesgo de duplicidad analítica y blindar la integridad referencial del posterior esquema en estrella.

Gracias a la ejecución secuencial de estos comandos, se garantiza que la información descriptiva que llega a MySQL sea completamente uniforme, robusta y esté optimizada para la creación de dimensiones en el modelado en estrella posterior.




Figura 27: Flujo ETL después de la transformación

3.4.4. Fase de carga de datos a la BBDD

3.4.4.1. Configuración del componente tDBOutput

La etapa final del proceso ETL consiste en la inserción física de los datos limpios y transformados en el sistema gestor de bases de datos relacionales (MySQL). Para ejecutar esta operación, se incorporó al final del flujo el componente de escritura correspondiente, en este caso, un componente de tipo **tDBOutput**.

Tal y como se detalla en la configuración del componente, el proceso de carga se estructuró en base a los siguientes parámetros técnicos:

1. **Parámetros de conexión:** Para mantener la coherencia y centralización del proyecto, las credenciales de acceso se definieron de forma directa (Property Type: Built-In). El componente apunta al servidor local (Host: “localhost”, puerto “3306”), conectándose a la base de datos **rendimiento_transformado** mediante el usuario administrador “root”).
2. **Definición del destino:** Se especificó explícitamente la tabla “**rendimiento_unico**” como el objeto contenedor que recibirá el flujo de registros provenientes de la etapa de transformación.
3. **Acción sobre la tabla (Action on table):** Se configuró la opción **Drop table if exists and create** (Eliminar tabla si existe y crear). Esta es una decisión de diseño arquitectónico fundamental, ya que establece una estrategia de carga completa. Al seleccionar esta opción, se le indica al motor de Talend que elimine la tabla previa y la genere de nuevo desde cero antes de volcar la nueva información. Esto garantiza que la estructura de la tabla esté siempre sincronizada con el esquema definido en el ETL y evita que se corrompa la integridad del histórico por ejecuciones previas.
4. **Acción sobre los datos (Action on data):** Se estableció el modo **Insert**, instruyendo al sistema para que procese el flujo de entrada ejecutando sentencias de inserción estándar por cada fila estandarizada, filtrada y enriquecida en el paso anterior.




Figura 28: Configuración del componente tDBOutput.

Con la finalización de esta fase de carga, el ciclo de vida de la integración de datos (ETL) se da por concluido. La base de datos MySQL queda poblada con una “única versión de la verdad”, estructurada y optimizada para ser consumida directamente por PowerBI en la siguiente fase del proyecto.

3.4.4.2. Ejecución del proceso y verificación de resultados

Una vez finalizada la configuración de todos los componentes del flujo ETL, se procedió a la ejecución del *Job* principal desde el entorno de Talend Open Studio. Tras confirmar que el proceso finalizó de manera exitosa, procesando todas las filas y sin arrojar errores de compilación o de formato en la consola, resultó imprescindible validar empíricamente que la información había persistido correctamente en el sistema destino.




Figura 29: Flujo de datos completo del proceso de ETL.

Para llevar a cabo esta comprobación técnica, se accedió al cliente de administración de bases de datos conectado al servidor MySQL local. Mediante la ejecución de una consulta SQL de selección estándar:

```
SELECT * FROM rendimiento_unico
```

Se interrogó a la base de datos para extraer los registros recién almacenados. Tal y como reflejan los resultados devueltos por la consulta, la tabla destino fue poblada exitosamente. Se pudo verificar de primera mano que todas las lógicas de negocio diseñadas en las fases previas se aplicaron de forma correcta:

1. Las métricas numéricas (como número de matrículas, rendimiento) se insertaron respetando sus tipos de datos.
2. El número de registros es lo mismo tanto en el job como en la base de datos.
3. Se visualizan los campos enriquecidos calculados durante el mapeo, destacando especialmente la generación de la clave primaria (**id_unico_powerbi**), fundamental para el posterior modelado.

Figura 30: Resultado de la consulta de verificación en MySQL.

Con esta validación en el gestor relacional, se da por concluida de manera satisfactoria la etapa de ingeniería de datos. El repositorio queda consolidado como una fuente estructurada, limpia y completamente preparada para ser explotada por la herramienta de visualización en la siguiente fase del proyecto.

3.5. Implementación de Power BI

Una vez que los datos han sido procesados, estandarizados y cargados en el servidor MySQL, se procede a la fase de explotación de la información. Para ello, se ha seleccionado Power BI como herramienta de Business Intelligence, debido a su potencia en el modelado de datos y su capacidad de conexión nativa con sistemas gestores de bases de datos relacionales.

3.5.1. Conexión y extracción de datos desde MySQL

El primer paso de la implementación consiste en establecer un puente de comunicación entre el motor analítico de Power BI y la base de datos alojada en MySQL.

Los pasos seguidos para la importación fueron los siguientes:

1. **Selección del conector:** Dentro de Power BI, se accedió al menú “Obtener datos”. En el catálogo de orígenes disponibles, se seleccionó el conector específico de “Base de datos MySQL”.
2. **Configuración de la cadena de conexión:** Tras seleccionar el conector, se especificaron los parámetros del servidor:
 - **Servidor:** aquí como nuestra base de datos está en el ordenador, es decir, en local, entonces escribimos `localhost`, indicando que la base de datos se encuentra en la misma máquina local.
 - **Base de datos:** `rendimiento_transformado`, correspondiente al nombre de la base de datos.




Figura 31: Configuración de los parámetros de red para la conexión local con MySQL.

3. **Autenticación y selección de tablas:** Tras introducir las credenciales de acceso (usuario root y contraseña), el sistema mostró un navegador con las tablas disponibles. Se seleccionó la tabla **rendimiento_unico**, que es la que contiene todos los campos enriquecidos y limpios procedentes de Talend.




Figura 32: Autenticación para conectar con MySQL




Figura 33: Navegador de tablas y sus registros

3.5.2. Creación del campo categórico Repetidor_Nuevo mediante agrupamiento

Para optimizar la legibilidad del dashboard final y facilitar la interpretación de las gráficas por parte del usuario, se detectó la necesidad de transformar el campo original **Es_Nuevo**. Este campo, procedente directamente de la fase ETL, se almacenaba como un tipo entero (INT) con valores binarios: 0 y 1.

Si bien esta estructura es eficiente para el almacenamiento en la base de datos MySQL, su uso directo en Power BI resultaba problemático. Al utilizar **Es_Nuevo** en los ejes o leyendas de los gráficos, el sistema mostraba únicamente los números “0” y “1”, lo cual no es intuitivo y obliga al usuario final a conocer de antemano la codificación técnica de los datos.

Para subsanar esta carencia de legibilidad, se optó por una solución nativa de Power BI mediante la creación de un “Nuevo Grupo de Datos”. El objetivo fue asignar etiquetas de texto descriptivas y significativas a cada uno de los valores numéricos originales.

Tal y como se ilustra en la Figura 34, el proceso técnico detallado fue el siguiente:

1. En el panel de datos, se localizó el campo original **Es_Nuevo**. Se accedió al menú contextual mediante el botón derecho del ratón sobre dicho campo y se seleccionó la opción “Nuevo grupo”.
2. En la ventana de configuración resultante, se estableció un nuevo nombre identificativo para el grupo: **Repetidor_Nuevo**.
3. Se seleccionó el “Tipo de grupo” como “Lista”.
4. En la columna de “Valores no agrupados”, se visualizaron los valores distintivos presentes en la columna original: 0 y 1.
5. Se seleccionaron ambos valores y se pulsó el botón “Agrupar”. Esto creó una estructura de grupos editable.

- Finalmente, bajo la columna “Grupos y miembros”, se procedió a renombrar las etiquetas por defecto. El grupo que contenía el valor numérico 0 fue renombrado a “Repetidor”, mientras que el grupo asociado al valor 1 se renombró a “Nuevo”.




Figura 34: Configuración del grupo de datos Repetidor_Nuevo en Power BI.

La utilidad fundamental de este nuevo campo se constata en la Figura 35. Como se puede apreciar en gráficas clave como por ejemplo: “Cuánta carga de repetidor tiene la universidad?”, esta gráfica del informe de visión general tiene la leyenda con categorías claras “Nuevo” (en azul claro) y “Repetidor” (en azul oscuro/negro), permitiendo un análisis directo y comprensible de los datos sin necesidad de descodificar valores numéricos.




Figura 35: Aplicación de las etiquetas de grupo en las leyendas de los gráficos del dashboard.

3.5.3. Métrica de Tasa de Atascamiento por Asignatura

Con el propósito de identificar de forma operacional las asignaturas que actúan como cuellos de botella dentro de los planes de estudio de la ETSISI, se ha diseñado e implementado una métrica analítica denominada **Tasa de Atascamiento**.

Es crítico señalar que, debido a la granularidad del repositorio de datos disponible, este indicador no evalúa el abandono institucional definitivo. En su lugar, se focaliza en el **micro-abandono** o estancamiento académico recurrente.

Frente a las funciones de agregación implícitas que ofrece la interfaz por defecto de Power BI, las cuales ejecutan promedios planos sobre porcentajes precalculados errando en la ponderación, esta métrica se ha desarrollado como una medida explícita utilizando el lenguaje DAX, garantizando la coherencia matemática en cualquier nivel de agregación o granularidad visual.

3.5.3.1. Lógica de Negocio y Formulación Matemática

El indicador propuesto no computa de manera genérica a todo el alumnado expuesto a una situación de riesgo(aquellos en su tercera matrícula o superior), sino que refina la ventana analítica para aislar exclusivamente a los estudiantes que, estando bajo dicha condición límite, no logran superar la asignatura en el año académico evaluado.

Matemáticamente, la tasa se define formalmente mediante la ecuación 3.1:

$$\text{Tasa de Atascamiento} = \frac{\sum \text{Matriculados}_{\geq 3} - \sum \text{Aprobados}_{\geq 3}}{\sum \text{Matriculados}} \quad (3.1)$$

Donde el numerador representa el volumen neto de estudiantes en situación de vulnerabilidad que han suspendido de la asignatura, mientras que el denominador representa el universo total de alumnos matriculados.

3.5.3.2. Implementación del Modelo Explicito en DAX

Para optimizar el rendimiento del motor analítico VertiPaq y garantizar la legibilidad y mantenimiento del código, la medida se estructuró mediante la declaración de variables locales (**VAR**). El código fuente implementado en la capa de modelado de Power BI se detalla a continuación:

```

Tasa_Atascamiento =
VAR AlumnosRiesgoMatriculados =
CALCULATE(
SUM(Fact_rendimiento_transformado[N__Matriculados]),
Fact_rendimiento_transformado[Numero_de_Matriculas] >= 3
)

VAR AlumnosRiesgoAprobados =
CALCULATE(
SUM(Fact_rendimiento_transformado[N__Aprobados]),
Fact_rendimiento_transformado[Numero_de_Matriculas] >= 3
)

VAR AlumnosRiesgoSuspendidos = AlumnosRiesgoMatriculados -
AlumnosRiesgoAprobados

VAR TotalMatriculadosGlobal = SUM(Fact_rendimiento_transformado[N__Matriculados])

RETURN
DIVIDE(
AlumnosRiesgoSuspendidos,
TotalMatriculadosGlobal,
0
)

```

Esta métrica se ha diseñado con el propósito de diagnosticar qué materias del catálogo académico suponen una barrera crítica en el avance de los estudiantes. Su valor reside en su capacidad para simplificar la gestión docente, permitiendo a los coordinadores de titulación y departamentos identificar de forma visual y centralizada los focos de vulnerabilidad académica que requieren una intervención o reestructuración pedagógica inmediata.

3.5.4. Modelado de Datos: Arquitectura de Esquema en Estrella

En esta fase del proyecto se ha procedido a la transformación de la estructura de datos desnormalizada (proveniente de la ingesta en MySQL) hacia un modelo dimensional optimizado. El objetivo principal es organizar la información siguiendo el estándar de industria de Esquema en Estrella para maximizar la eficiencia analítica y el rendimiento de las consultas en el motor de Power BI.

3.5.4.1. Justificación: Tabla Plana frente a Modelo Dimensional

Originalmente, los datos se presentaban en una estructura única o "tabla plana", donde cada registro contenía información redundante de asignaturas, planes de estudio y año académico. Se decidió migrar a un esquema en estrella por las siguientes ventajas técnicas:

- **Eficiencia en el motor de almacenamiento:** Power BI utiliza **VertiPaq**, un motor orientado a columnas. Al segregar las descripciones textuales en dimensiones y mantener únicamente claves numéricas en la tabla de hechos, se optimiza la compresión y se reduce la huella de memoria RAM.

- **Mantenibilidad y Consistencia:** Se elimina la redundancia de datos. Cualquier actualización en los metadatos de un plan o asignatura se realiza en un único punto (la dimensión), evitando inconsistencias nominales en los registros históricos de rendimiento.
- **Propagación de Filtros:** Las medidas DAX operan con mayor agilidad cuando los filtros fluyen desde las dimensiones hacia una tabla de hechos centralizada, evitando el escaneo innecesario de tablas denormalizadas de gran volumen.

3.5.4.2. Proceso de Construcción de Dimensiones

Para la construcción del modelo multidimensional, el proceso de segmentación y refinamiento se ejecuta dentro del editor de Power Query, integrado en el motor de transformación de Power BI. Con el objetivo de garantizar la modularidad y salvaguardar la integridad referencial, se adoptó una estrategia de linaje de datos basada en consultas vinculadas.

En primer lugar, a partir de la tabla plana original, se generó una **Referencia** mediante el menú contextual de la herramienta. Esta consulta derivada se estableció como la entidad central o **Tabla de Hechos (Fact_rendimiento_transformado)**. Posteriormente, utilizando esta última como nodo raíz, se crearon tres referencias adicionales orientadas a la construcción física de las dimensiones analíticas: **dim_asignatura**, **dim_plan_de_estudio** y **dim_tiempo**. Este enfoque de desacoplamiento arquitectónico optimiza el consumo de memoria y asegura que cualquier traza o limpieza estructural sobre la tabla de hechos se propague de manera nativa y consistente hacia las dimensiones subordinadas.

Para la materialización y el modelado definitivo de cada una de estas dimensiones, se procedió con la ejecución secuencial de las siguientes fases técnicas:

3.5.4.2.1 Selección de Atributos y Granularidad:

Se empleó la función **Table.SelectColumns** para hacer una referencia de la tabla plana y solo seleccionar las columnas que queremos. Este paso es fundamental para establecer la granularidad correcta :

```
= Table.SelectColumns(
    rendimiento_transformado_rendimiento_unico,
    { "Columna1", "Columna2", "Columna3" }
)
```

3.5.4.2.2 Normalización y Eliminación de Duplicados:

Para garantizar que la relación entre la dimensión y la tabla de hechos sea de tipo 1 : N, se aplicó un protocolo de limpieza de duplicación. Aplicando la función **Table.Distinct** centrada exclusivamente en las claves. Esto asegura que cada asignatura sea una entidad única en el catálogo.

```
= Table.Distinct(
    #"Paso de selección de columnas"
)
```

3.5.4.2.3 Generación de Claves Subrogadas (Surrogate Keys):

Siguiendo los principios de diseño de Kimball, se añadió un identificador numérico entero e independiente de la fuente original para cada dimensión. Esto permite desvincular el modelo de la lógica de negocio externa y acelera los joins internos del motor:

```
= Table.AddIndexColumn(
#"Paso de eliminación de duplicados",
"Nombre del índice",
0, 1, Int64.Type
)
```

The screenshot shows a table with multiple columns. The first column contains a list of dimension names, such as 'Dimensión de Tiempo', 'Dimensión de Ubicación', 'Dimensión de Producto', etc. The second column contains surrogate keys, which are numerical values. The table is displayed in a grid format with a header row and several data rows.

Figura 36: Ejemplo de una dimension creada.

3.5.4.3. Estructuración de la Tabla de Hechos (Fact Table)

La tabla `Fact_rendimiento` constituye el núcleo del modelo y almacena las métricas cuantitativas del estudio. Su construcción se basó en un proceso de sustitución de metadatos por claves técnicas:

- **Resolución de Claves:** Mediante la operación `Table.NestedJoin`, se vincularon los registros de rendimiento con cada dimensión maestra utilizando sus códigos naturales como punto de anclaje:

```
= Table.NestedJoin(
Paso previo,
{ "columnas de la clave de dimension en la tabla de
hecho"},
dimension,
{ "columnas de la clave de dimension"},
"nombre de clave foránea tras join",
JoinKind.LeftOuter
)
```

- **Refinado y Limpieza Final:** Se eliminaron todas las columnas descriptivas originales, resultando en una tabla de hechos de alta densidad compuesta por claves foráneas y métricas:

```

= Table.SelectColumns(
#"Paso previo",
{
"Numero_de_Matriculas", "N_Matriculados", "N_Aprobados",
"Rendimiento", "Eficiencia.en.matricula",
"ID.Unico.PowerBI",
"Es_Nuevo", "dim_asignatura.ID_Asignatura_SK",
"dim_plan_de_estudio.ID_Plan_de_Estudios_SK",
"dim_tiempo.ID_Anio_Academico_SK"
}
)

```




Figura 37: Tabla de hecho creada.

Este diseño final garantiza la consolidación de una **Single Source of Truth** (SSOT) o fuente única de verdad, asegurando la consistencia de los datos en todo el ecosistema del informe. Asimismo, permite una navegación multidimensional fluida y eficiente a través de todos los indicadores académicos del proyecto, facilitando el análisis descriptivo y predictivo. Como resultado de este proceso, el modelo de datos se articula bajo una arquitectura de esquema en estrella, cuya disposición lógica se detalla a continuación:




Figura 38: Modelo de estrella.

3.5.5. Diccionario de Datos del Modelo Dimensional

Con el propósito de garantizar la transparencia, la gobernanza del dato y facilitar la auditoría del modelo analítico, se detalla a continuación el diccionario de datos. Este componente documenta la semántica, el tipo de dato y la función técnica de cada variable, clasificadas según su pertenencia a la tabla de hechos o a las tablas de dimensiones del esquema en estrella.

3.5.5.1. Tabla de Hechos: Fact_rendimiento_transformado

La tabla central del modelo consolida los indicadores cuantitativos de rendimiento académico junto con las claves subrogadas necesarias para establecer las uniones dimensionales.

Campo	Tipo de Dato	Descripción
ID_Asignatura_SK	Entero	Clave subrogada para la vinculación inequívoca con la dimensión de asignaturas.
ID_Plan_de_Estudios_SK	Entero	Clave subrogada para la vinculación con el catálogo maestro de planes de estudio.
ID_Anio_Academico_SK	Entero	Clave subrogada de base temporal para filtrar por periodos académicos.
ID_Unico_PowerBI	Cadena	Clave primaria compuesta en origen mediante concatenación, utilizada para auditoría de duplicados.
N_Matriculados	Entero	Número total de alumnos formalmente matriculados en el grupo.
N_Aprobados	Entero	Cantidad total de alumnos que obtuvieron una calificación cuantitativa igual o superior al aprobado.
Numero_de_Matriculas	Entero	Número de matrícula del grupo (convocatorias recurrentes).
Rendimiento	Decimal	Métrica porcentual continua que mide la tasa de éxito directo sobre los presentados. La fórmula para calcular este indicador es : $\text{Número de aprobados} / \text{Número de matriculados}$.
Eficiencia_en_matricula	Decimal	Métrica ponderada que evalúa la eficiencia académica en función del número de convocatorias consumidas. Se calcula analíticamente como $\text{rendimiento} / \text{Número de matrículas}$.
Es_Nuevo	Binario (0/1)	Variable dicotómica que identifica si el registro pertenece a un grupo de nuevo ingreso (1) o repetidor (0).
Nuevo_Repetidor	Cadena	Atributo categórico derivado que clasifica cualitativamente el perfil del alumnado en el grupo.
Tasa_Atascamiento	Decimal	Métrica continua que cuantifica el nivel de retención indeseada o dificultad en el progreso. Se calcula mediante la tasa de suspensiones de tercer matrícula o más/ total de matriculados.

Tabla 1: Diccionario de datos de la tabla de hechos Fact_rendimiento.

3.5.5.2. Dimensión: dim_asignatura

Entidad maestra que almacena los atributos descriptivos fijos asociados a la oferta académica de asignaturas.

Campo	Tipo de Dato	Descripción
ID_Asignatura_SK	Entero	Clave primaria de la dimensión. Clave autoincremental generada artificialmente por PowerBI.
Codigo_Asignatura	Cadena	Clave natural u origen. Código alfanumérico que identifica la asignatura en la base de datos institucional.
Nombre_Asignatura	Cadena	Denominación oficial de la asignatura (etiqueta limpia sin tildes ni caracteres especiales tras el proceso ETL).
Tipo_Asignatura	Cadena	Tipología académica de la materia.
Curso	Entero	Nivel académico del plan de estudios en el que se imparte preferentemente la asignatura (1º, 2º, etc.).
Tipo_Convalidacion	Cadena	Atributo de control que indica si la asignatura posee una naturaleza convalidada o reconocida.

Tabla 2: Diccionario de datos de la dimensión dim_asignatura.

3.5.5.3. Dimensión: dim_plan_de_estudio

Catálogo estructurado que define los programas académicos y titulaciones vigentes en la ETSISI.

Campo	Tipo de Dato	Descripción
ID_Plan_de_Estudios_SK	Entero	Clave primaria autoincremental de la dimensión de planes de estudio.
Codigo_Plan_de_Estudios	Cadena	Clave natural identificativa del plan de estudios o titulación académica.
Nombre_Plan_de_Estudios	Cadena	Nombre descriptivo oficial de la titulación o grado universitario.
Nivel_de_Estudios	Cadena	Categorización del nivel formativo del programa (Grado, Máster Universitario).
Tipo_Especial	Cadena	Atributo cualitativo para representar el tipo del grado o titulación académica.
Codigo_Centro	Cadena	Identificador del centro o escuela responsable de la impartición del plan.

Tabla 3: Diccionario de datos de la dimensión dim_plan_de_estudio.

3.5.5.4. Dimensión: dim_tiempo

Tabla dimensional dedicada a proveer un contexto temporal uniforme y estandarizado para las métricas del modelo.

Campo	Tipo de Dato	Descripción / Regla de Negocio
ID_Anio_Academico_SK	Entero	Clave primaria que identifica de forma unívoca a cada periodo temporal en el modelo.
Anio_Academico	Cadena	Representación textual del curso académico en formato estandarizado (v.g., "2024-2025").

Tabla 4: Diccionario de datos de la dimensión dim_tiempo.

Capítulo 4

Resultados

4.1. Resultados obtenidos

4.1.1. Visualización de Datos y Diseño del Dashboard

Tras completar el modelado de datos y la creación de medidas, se ha procedido al diseño de la interfaz visual en Power BI. El objetivo principal del dashboard es permitir una exploración intuitiva de los indicadores académicos, facilitando la identificación de patrones y áreas de mejora. El informe se ha estructurado en tres páginas principales, accesibles mediante un menú de navegación lateral.

4.1.1.1. Página 1: Visión General

Esta página constituye el punto de entrada al análisis y ofrece una perspectiva de alto nivel sobre el estado de la institución (Figura 39). El diseño de la interfaz se organiza de forma limpia en tres componentes principales:

1. **Indicadores Clave de Rendimiento (KPIs):** Dispuestos en la franja superior, consisten en **tres tarjetas** cuantitativas que muestran los valores agregados globales del histórico analizado: el volumen total de matriculados, el promedio de rendimiento y el promedio de eficiencia en la matrícula.
2. **Análisis de Tendencias y Distribución de Carga:** La sección inferior central de la pantalla se desglosa en dos bloques visuales complementarios:
 - **Gráfico de líneas (Promedio de Rendimiento por Año):** Permite evaluar de forma longitudinal la evolución temporal paralela tanto del rendimiento académico como de la eficiencia en la matrícula a lo largo de los cursos cronológicos.
 - **Gráfico de anillos (¿Cuánta “carga” de repetidor tiene la universidad?):** Expresa la distribución estructural de la población estudiantil, reflejando de manera directa el peso de los alumnos de nuevo ingreso frente al volumen de alumnos repetidores.
3. **Filtros Globales Contextuales:** En la esquina superior derecha se han integrado dos segmentadores de datos desplegables que permiten alterar dinámicamente el contexto de filtro de todo el lienzo, aislando la información de acuerdo al **Año Académico** o al **Curso** seleccionado.




Figura 39: Página de Visión General.

4.1.1.2. Página 2: Análisis de asignatura

Esta página sirve para analizar en detalle las asignaturas, bajando del nivel general de la universidad a un estudio centrado en cada materia (Figura 40). El objetivo es ver de forma rápida cuáles son las asignaturas más complicadas de la escuela mediante tres elementos principales interconectados:

1. **Matriz de Rendimiento Promedio por Asignatura:** Está situada a la izquierda y es una tabla que muestra el listado de asignaturas junto con su porcentaje de rendimiento medio. Sirve para comparar de forma directa el nivel de aprobados entre las distintas materias.
2. **Nº de repetidores por Asignatura:** Es el gráfico de barras de arriba a la derecha. Muestra la cantidad total de alumnos repetidores que tiene cada asignatura, lo que ayuda a ver qué clases tienen un mayor problema de masificación.
3. **Tasa de atascamiento por Asignatura:** Es el gráfico de barras grande que ocupa la parte de abajo. Este gráfico utiliza la medida DAX que explicamos en la Sección de desarrollo. Al centrarse solo en los alumnos que suspendieron su tercera matrícula o más, permite detectar los verdaderos cuellos de botella de la escuela, sin importar el tamaño total de la clase.
4. **Filtros Globales:** En la esquina superior derecha se incluyen los selectores de Año Académico y Curso para poder filtrar los tres gráficos de la pantalla a la vez.



Esta estructura de visualización garantiza que los responsables académicos no solo conozcan la situación actual, sino que puedan detectar tendencias de degradación o mejora en el rendimiento de asignaturas específicas a lo largo del tiempo, permitiendo una gestión proactiva basada en datos.

En este capítulo se describen las pruebas realizadas para validar la integridad de la información y el correcto funcionamiento de las herramientas empleadas. En un proyecto de estas características, la calidad del dato es crítica; un error en la fase de transformación podría dar lugar a conclusiones erróneas en el análisis estratégico. Por ello, se ha seguido una estrategia de validación en cascada, empezando por el proceso ETL y terminando en la capa de usuario.

El plan de pruebas se ha diseñado para cubrir los siguientes objetivos principales:

4.2.2. Pruebas de integridad en el proceso ETL

4.2.2.1. Validación de valores nulos y vacíos

Se han implementado sobre los campos que componen la clave (Año, Plan de Estudios, Asignatura y Curso). Utilizando expresiones de filtrado en el componente **tMap**, se asegura que cualquier registro que contenga valores nulos o cadenas de texto vacías sea descartado antes de la carga. Esta prueba es vital para evitar errores en la posterior creación de la clave compuesta “ID_Unico_PowerBI”.

```
// 1. Validar el Año
row3.Ano_Academico != null && row3.Ano_Academico.trim().length() > 0 &&

// 2. Validar el Plan
row3._Plan_de_estudios != null && row3._Plan_de_estudios.trim().length() > 0 &&

// 3. Validar la Asignatura
row3.Asignatura != null && row3.Asignatura.trim().length() > 0 &&

// 4. Validar el N° de Matricula
row3.Numero_de_Matriculas != null && row3.Numero_de_Matriculas > 0 &&

// 5. Validar el N° de Curso
row3.Curso != null && row3.Curso > 0
```


Figura 42: Código de la prueba de integridad

Con el objetivo de verificar el correcto funcionamiento de los filtros implementados en el proceso ETL, se ha realizado una prueba de integridad técnica mediante la ejecución de una sentencia SQL sobre la tabla final en el entorno de MySQL:

```
1 • SELECT *
2 FROM dato_transformado_tabla_unica
3 WHERE (Ano_Academico IS NULL OR Ano_Academico = '')
4 OR (_Plan_de_estudios IS NULL OR _Plan_de_estudios = '')
5 OR (Asignatura IS NULL OR Asignatura = '')
6 OR (Numero_de_Matriculas IS NULL OR Numero_de_Matriculas <= 0)
7 OR (Curso IS NULL OR Curso <= 0);
```

Figura 43: Sentencia SQL para la validación de integridad y rangos numéricos.

Finalmente, tal como se observa en la captura del resultado (Figura 44), la ejecución de la consulta no devuelve ningún registro. Este resultado (0 filas retornadas) evidencia la ausencia de datos nulos o inconsistentes, confirmando que la totalidad de la información almacenada cumple estrictamente con las normas de integridad y las reglas de negocio definidas previamente.



The screenshot shows a database query result in a table format. The table has columns: Plan_de_estudios, Nivel_de_Estudios, Tipo_Especial, Ano_Academico, Numero_de_Matriculas, N_Matriculados, N_Aprobados, Rendimiento, and Eficiencia. Below the table, there is a section for 'Output' with a table showing the execution details: 1 row returned, 0.015 sec / 0.000 sec.

Plan_de_estudios	Nivel_de_Estudios	Tipo_Especial	Ano_Academico	Numero_de_Matriculas	N_Matriculados	N_Aprobados	Rendimiento	Eficiencia
------------------	-------------------	---------------	---------------	----------------------	----------------	-------------	-------------	------------

Output

Action	Time	Action	Message	Duration / Path
1	00:34:08	SELECT	FROM dato_transformado_tabla_unica WHERE (Ano_Ac...	0 rows returned 0.015 sec / 0.000 sec

Figura 44: Resultado de la consulta de integridad.

4.2.2.2. Control de unicidad de registros

Para verificar que cada hecho académico se computa una sola vez, se ha implementado el componente **tUniqueRow**. Este componente realiza una comprobación en memoria durante la ejecución del *Job* para detectar colisiones en la clave compuesta “ID_Unico_PowerBI”.

La prueba consiste en procesar el volumen total de datos y verificar que el flujo de salida de “duplicados” es gestionado correctamente, enviando únicamente los registros únicos a la base de datos. Con esto se garantiza que el dashboard no infle los números por culpa de redundancias en la fuente original.

Para ver el resultado de esta prueba, podemos observar las siguientes imágenes Figura 45 y Figura 46, podemos ver que el total registros cargados antes y después de la prueba es los mismo, es decir que en nuestra fuente no hay claves con valores duplicadas.




Figura 45: Resultado de la ejecución de cargar datos sin prueba de unicidad.




Figura 46: Resultado de la ejecución de cargar datos con prueba de unicidad.

Con el objetivo de aportar mayor rigor científico a la investigación y validar empíricamente la unicidad de la clave **ID_Unico_PowerBI**, se ejecutó la siguiente consulta de en MySQL para comprobarla. La Figura 47 muestra el resultado de dicha ejecución, confirmando un conjunto de resultado vacío, lo que demuestra que la restricción de unicidad del identificador **ID_Unico_PowerBI** se cumple en la totalidad de las filas.





Figura 47: Resultado de la ejecución de la consulta de prueba de la unicidad de la clave compuesta.

En conclusión, el éxito de las ejecuciones de las pruebas demuestran que

el sistema es robusto. Los filtros han actuado como una malla de seguridad eficaz, garantizando que el 100 % de los datos cargados en la base de datos **rendimiento_transformado** son registros únicos, completos y listos para ser explotados en Power BI sin riesgo de inconsistencias.

4.2.2.3. Validación de Calidad de Datos: Resiliencia ante Inconsistencias de Diacríticos

Durante la fase de perfilado de datos inicial, se detectó una vulnerabilidad crítica de integridad semántica en la extracción de los planes de estudio y asignaturas. El origen de datos presentaba registros duplicados debido a la coexistencia de cadenas con discrepancias en caracteres diacríticos (tildes). Un ejemplo representativo de esta anomalía era la coexistencia de las cadenas "ADMINISTRACIÓN" y "ADMINISTRACION" para hacer referencia a una misma entidad. Este error lo podemos encontrar aplicando la siguiente consulta en MySQL:



```

32 • SELECT
33     Nombre_Asignatura,
34     COUNT(DISTINCT Codigo_Asignatura) AS Num_Codigos,
35     COUNT(*) AS Total_Registros
36 FROM
37     rendimiento_unico
38 WHERE
39     Nombre_Asignatura LIKE 'ADMINISTRACI%'
40 GROUP BY
41     Nombre_Asignatura,
42     BINARY Nombre_Asignatura;

```

Nombre_Asignatura	Num_Codigos	Total_Registros
ADMINISTRACION DE SISTEMAS OPERATIVOS	2	9
ADMINISTRACIÓN DE SISTEMAS OPERATIVOS	2	11
ADMINISTRACIÓN Y GESTIÓN DE BASES DE DA...	1	12
ADMINISTRACIÓN Y GESTIÓN DE BASES DE DA...	2	19
ADMINISTRACION Y GESTIÓN DE REDES	1	7
ADMINISTRACIÓN Y GESTIÓN DE REDES	2	8

Figura 48: Consulta para detectar error de tilde

Para garantizar que los componentes de transformación desarrollados en Talend mitigan este defecto antes de la persistencia en el almacén de datos, se diseñó un escenario de prueba unitaria de caja negra enfocado en la sanitización de cadenas.

El objetivo de la prueba consiste en verificar la invarianza del flujo ETL ante variaciones ortográficas, asegurando que cadenas semánticamente idénticas pero con diferencias de formato físico converjan en una única clave subrogada de dimensión. El diseño sintético del caso de prueba se detalla en la Tabla 5.

Para solucionar este problema, aplicamos en el motor de ejecución la expresión de transformación unificada en Talend:

```

TalendString.removeAccents(
row3.Plan_de_estudios.split("- ")[1].trim()
).toUpperCase()


```

Con el fin de estandarizar el formato de entrada, se utiliza la función **removeAccents** para la eliminación de acentos y el método **toUpperCase()**

ID de Prueba	CP-DQ-001
Componente	Proceso ETL
Descripción	Verificación del tratamiento masivo de acentos y capitalización en el nombre del plan de estudios.
Criterio de Éxito	El sistema debe eliminar diacríticos, limpiar espacios redundantes y unificar el texto en mayúsculas planas.
Estado Final	Exitoso (<i>Passed</i>)

Tabla 5: Especificación del caso de prueba unitaria para la limpieza de texto.

para asegurar la consistencia en mayúsculas. Esta transformación conjunta se implementa como una regla de validación por diseño. Aunque el flujo de origen procesa los datos teóricamente capitalizados, esta capa de limpieza neutraliza las inconsistencias de caja provocadas por errores humanos en la manipulación de los sistemas transaccionales intermedios.



```

32 • SELECT
33     Nombre_Asignatura,
34     COUNT(DISTINCT Codigo_Asignatura) AS Num_Codigos,
35     COUNT(*) AS Total_Registros
36 FROM
37     rendimiento_unico
38 WHERE
39     Nombre_Asignatura LIKE 'ADMINISTRACI%'
40 GROUP BY
41     Nombre_Asignatura,
42     BINARY Nombre_Asignatura;

```

Nombre_Asignatura	Num_Codigos	Total_Registros
ADMINISTRACION DE SISTEMAS OPERATIVOS	4	20
ADMINISTRACION Y GESTION DE BASES DE DA...	3	31
ADMINISTRACION Y GESTION DE REDES	3	15

Figura 49: Resultado de la misma consulta después de aplicar los métodos

4.2.3. Lecciones Aprendidas

4.2.3.1. Importancia de la Validación Temprana

La decisión de implementar controles de calidad en las primeras etapas del flujo de datos, antes de su almacenamiento definitivo, ha permitido:

- **Evitar la propagación de errores:** Detectar inconsistencias en la fase de captura impide que los datos “sucios” afecten a los cálculos del dashboard y a la toma de decisiones.
- **Garantizar la integridad desde el origen:** Asegurar que solo la información que cumple con los requisitos mínimos de completitud sea procesada, actuando como un primer filtro de seguridad.
- **Reducción de la deuda técnica:** Es mucho más sencillo y económico corregir un error en la fase de extracción que intentar depurar una métrica

incorrecta cuando ya está visualizada en el informe final.

4.2.3.2. Automatización de Pruebas y Validación Continua

Sustituir las revisiones manuales por una lógica de validación sistemática dentro del proceso de datos ha proporcionado:

- **Ejecución sistemática y objetiva:** Garantizar que cada registro pase exactamente por los mismos controles de calidad, eliminando la posibilidad de error humano en la supervisión.
- **Escalabilidad del sistema:** Capacidad para procesar nuevos volúmenes de datos manteniendo la confianza de que se aplicarán las mismas reglas de limpieza de forma automática.
- **Detección inmediata de anomalías:** Identificar de forma instantánea cualquier desviación en el formato o la estructura de los datos de entrada, facilitando una respuesta rápida ante cambios en la fuente de origen.

Capítulo 5

Conclusiones y trabajos futuros

5.1. Conclusiones

El desarrollo de este proyecto ha permitido transformar un conjunto de datos brutos y dispersos en una herramienta de visualización avanzada capaz de ofrecer *insights* críticos sobre el comportamiento del alumnado de la ETSISI.

La etapa final del presente trabajo contempla una evaluación reflexiva sobre los logros obtenidos, los obstáculos técnicos identificados y las vías de evolución del sistema. En este apartado se detallan las conclusiones fundamentales, se analizan críticamente las áreas susceptibles de perfeccionamiento y se establece una hoja de ruta con las líneas futuras para escalar y optimizar la solución ETL desarrollada.

5.1.1. Logros Principales

Uno de los principales logros del proyecto ha sido la implementación exitosa de un flujo ETL robusto que garantiza la calidad y trazabilidad de los datos académicos. La configuración de capas de validación en Talend se ha revelado como un componente fundamental para detectar y corregir problemas de integridad, como registros nulos o cadenas vacías antes de su almacenamiento en MySQL. Esta estrategia ha permitido eliminar duplicados mediante controles de unicidad, consolidando un repositorio final de 5.047 registros únicos que aseguran análisis totalmente confiables.

La integración de un modelo de datos relacional bajo un esquema de estrella ha optimizado significativamente el rendimiento de las consultas analíticas en Power BI. La estructuración adecuada de las tablas de dimensiones (Asignaturas, Plan de estudio y tiempo) y de hechos (Rendimiento) ha permitido que la interacción con el dashboard sea fluida y eficiente. El uso de una clave compuesta (`ID_Unico_PowerBI`) ha facilitado la vinculación precisa de los datos históricos de siete cursos académicos, resultando en un sistema mantenible y escalable para futuras ampliaciones.

5.1.2. Impacto en la Toma de Decisiones

La solución desarrollada ha transformado con éxito los datos transaccionales de origen en tres cuadros de mando interactivos (Visión General, Análisis de Asignatura y Análisis de Titulaciones) que facilitan la toma de decisiones basada en datos reales dentro de la escuela. Las visualizaciones implementadas permiten realizar análisis a diferentes niveles, desde una perspectiva macro de la institución hasta el detalle de una materia concreta.

El impacto práctico de estos informes se divide en tres niveles de decisión:

- **Planificación Institucional Global:** A través del informe de **Visión General**, los responsables pueden evaluar de un vistazo la salud de la universidad mediante los tres KPIs principales (matriculados, rendimiento global y eficiencia) y conocer exactamente la carga de alumnos repetidores frente a los nuevos, facilitando la previsión de grupos para el siguiente curso.
- **Gestión y Comparativa de Carreras:** La pantalla de **Análisis de Titulaciones** permite a la dirección comparar de forma directa el volumen de alumnos y el rendimiento entre los diferentes Grados y Másteres. Esto es clave para detectar desequilibrios, ayudando a redistribuir los recursos docentes donde más se necesitan.
- **Detección de Bloqueos por Materia:** El informe de **Análisis de Asignatura** aporta el mayor valor operativo. Al combinar el ranking de alumnos repetidores con el gráfico de la **Tasa de Atascamiento**, los coordinadores de estudios pueden aislar los verdaderos cuellos de botella de la escuela. Esto permite diferenciar las asignaturas que tienen muchos repetidores simplemente porque son masivas, de aquellas donde los estudiantes realmente se bloquean al llegar a su tercera matrícula o más, permitiendo priorizar tutorías o revisar las guías docentes de manera justificada.

En definitiva, este sistema dota a la universidad de una herramienta analítica fiable que elimina las suposiciones a la hora de diseñar planes de mejora educativa. Los resultados obtenidos demuestran que la limpieza previa de los datos y el modelado correcto de las métricas son pasos indispensables para que los gráficos muestren una realidad fiel y útil para el futuro de los estudiantes.

5.2. Desafíos y Limitaciones del Proyecto

El desarrollo del sistema ETL y el posterior análisis de datos han estado sujetos a una serie de condicionantes técnicos y operativos. Identificar estas limitaciones es fundamental para comprender el alcance actual de la solución y las decisiones de diseño adoptadas durante el desarrollo del TFG.

5.2.1. Limitaciones Tecnológicas y de Software

El uso de versiones gratuitas y de código abierto ha permitido la viabilidad económica del proyecto, pero ha impuesto ciertas restricciones en comparación con un despliegue en un entorno empresarial real:

- **Talend Open Studio:** Al emplear la versión gratuita, el sistema carece de funcionalidades de administración remota y planificación automática de tareas que ofrece la versión **Enterprise**. La ejecución de los *Jobs* depende de un entorno local, lo que limita la automatización en tiempo real.
- **MySQL Local:** El despliegue de la base de datos en un servidor local ha condicionado las pruebas de concurrencia. En un entorno productivo, se requeriría una instancia en la nube (como Azure SQL o AWS RDS) para garantizar la disponibilidad y escalabilidad de los datos.

- **Power BI Desktop:** La ausencia de una licencia Pro o Premium limita las capacidades de publicación en la nube y el uso de dashboards compartidos, restringiendo el consumo del informe a una visualización local o mediante el intercambio de archivos estáticos.

5.2.1.1. Calidad y Heterogeneidad de la Fuente de Datos

Uno de los mayores desafíos técnicos ha sido el tratamiento de la información original proporcionada:

- **Inconsistencias en el formato:** Los archivos fuente (CSV/Excel) de distintos años académicos presentaban variaciones en la nomenclatura de las columnas y el uso de caracteres especiales. Esto obligó a diseñar rutinas de limpieza de acentos y normalización de cadenas de texto específicas en el componente `tMap`.
- **Anonimización y granularidad:** Siguiendo la normativa de protección de datos, la información ha sido anonimizada. Aunque es una práctica necesaria, limita la capacidad del sistema para realizar un seguimiento individualizado del alumno a lo largo de toda su trayectoria académica, perdiéndose parte del linaje histórico del estudiante.

5.2.1.2. Volumen y Variedad de Datos

El alcance de la investigación se ha circunscrito a un volumen de información manejable, representativo del entorno universitario pero distante de las dimensiones de un ecosistema de producción empresarial masivo. Si bien los datos procesados permiten validar con éxito la lógica de negocio y la arquitectura del sistema, esta acotación ha condicionado la posibilidad de realizar pruebas de carga intensivas.

En consecuencia, no ha sido posible evaluar íntegramente la flexibilidad del modelo frente a una mayor heterogeneidad en el origen de los datos o ante flujos de información masivos.

5.3. Líneas Futuras

Tras la implementación de la solución actual, se han identificado diversas vías de evolución que permitirían transformar el sistema descriptivo en una herramienta de inteligencia avanzada. Las propuestas se dividen en cuatro ejes estratégicos:

5.3.1. Analítica Predictiva y Machine Learning

El sistema actual se centra en el análisis descriptivo. El siguiente paso lógico es la transición hacia la analítica predictiva, utilizando el histórico de datos ya limpio para anticipar escenarios futuros mediante:

- **Identificación del riesgo de abandono:** Entrenar modelos de clasificación que detecten qué estudiantes tienen una alta probabilidad de no superar el curso basándose en su comportamiento inicial y su histórico de repeticiones.

- **Modelado de la demanda de matrícula:** Aplicar algoritmos de regresión para anticipar el volumen de alumnos en cada asignatura para los próximos años, permitiendo una planificación mucho más ajustada de la oferta de plazas y horarios.
- **Análisis de tendencias de éxito:** Predecir la evolución de las tasas de éxito de una titulación a largo plazo, permitiendo a la dirección del centro evaluar si las reformas en los planes de estudio están surtiendo el efecto deseado.

5.3.2. Automatización del ciclo de carga y monitorización continua

Una evolución técnica necesaria para garantizar la sostenibilidad y la frescura de los datos sin intervención manual constante contempla:

- **Conexión directa con bases de datos transaccionales:** Configurar conectores que extraigan la información directamente del sistema de gestión de la universidad, eliminando la dependencia de archivos externos.
- **Implementación de cargas incrementales:** Desarrollar una lógica que identifique y procese solo los registros nuevos o modificados diariamente, optimizando el consumo de recursos de los servidores.
- **Sistema de alertas tempranas:** Programar notificaciones automáticas dirigidas a los coordinadores de grado cuando los indicadores de una asignatura caigan por debajo de un umbral crítico.

5.3.3. Migración a Entornos Cloud y Alta Disponibilidad

Con el fin de aumentar la potencia y la estabilidad del sistema frente a un volumen de datos creciente, se plantea:

- **Escalabilidad Elástica:** Utilizar servicios de nube (Azure, AWS o Google Cloud) para ampliar los recursos de procesamiento de forma instantánea durante los picos de matriculación.
- **Arquitectura de bajo coste:** Optimizar el presupuesto del proyecto mediante el uso de funciones en la nube que solo consuman recursos en el momento exacto de la carga de datos.
- **Seguridad y Disponibilidad Global:** Implementar políticas de copia de seguridad automatizadas y garantizar que los gestores puedan acceder a los informes de forma segura desde cualquier ubicación.

5.3.4. Enriquecimiento con Fuentes de Datos Externas

Cruzar los indicadores internos con información pública para aportar un contexto socioeconómico y profesional:

- **Estudio de Inserción Laboral:** Vincular las tasas de éxito académico con datos de empleabilidad del Ministerio de Trabajo para analizar la relación entre el rendimiento académico y el éxito profesional.

- **Contexto Geográfico y Movilidad:** Integrar datos sobre la procedencia de los alumnos para analizar si factores como el cambio de residencia influyen en el rendimiento de los alumnos de primer año.
- **Benchmarking Universitario:** Comparar los resultados propios con las medias nacionales publicadas en portales de transparencia para evaluar la competitividad del grado.
- **Impacto de Becas:** Cruzar los datos de rendimiento con la concesión de ayudas públicas para analizar cómo el apoyo económico influye en la continuidad de los estudiantes con menos recursos.

Capítulo 6

Aspectos Éticos, Legales y Medioambientales

6.1. Impacto Social y Educativo

La implementación de este sistema de Business Intelligence genera un impacto directo en la calidad de la gestión universitaria y, por extensión, en el bienestar del alumnado. La capacidad de identificar patrones de fracaso académico o “atascos” en asignaturas críticas permite:

- **Fomentar la igualdad de oportunidades:** Al detectar de forma temprana a los colectivos de alumnos repetidores con mayores dificultades, la institución puede diseñar programas de apoyo específicos, reduciendo las tasas de abandono.
- **Transparencia en la gestión académica:** Proporcionar una visión clara y objetiva del rendimiento por departamentos y planes de estudio promueve una cultura de rendición de cuentas y mejora continua basada en datos reales, no en percepciones.
- **Optimización del éxito estudiantil:** Facilitar que los responsables de titulación tomen decisiones informadas para ajustar metodologías docentes en aquellas materias donde el rendimiento es anómalamente bajo, mejorando la experiencia educativa global.

6.2. Impacto Medioambiental y Sostenibilidad

Aunque el proyecto es de naturaleza digital, su implementación contribuye a los objetivos de sostenibilidad de la institución mediante la optimización de recursos físicos y la digitalización de procesos:

- **Reducción de la huella de papel (Desmaterialización):** La sustitución de informes impresos y registros manuales por dashboards interactivos en la nube elimina la necesidad de generar documentación física recurrente, alineándose con las políticas de “cero papel” de la universidad.
- **Eficiencia operativa y energética:** La automatización del proceso ETL reduce drásticamente las horas de trabajo manual y el uso de recursos computacionales ineficientes, centralizando el esfuerzo en una arquitectura optimizada que minimiza el consumo energético de los servidores.
- **Planificación eficiente de infraestructuras:** Un mejor conocimiento del volumen de alumnos matriculados y sus tendencias de éxito permite

una gestión más precisa de los espacios físicos (aulas, laboratorios), evitando el desperdicio de recursos energéticos en instalaciones infrautilizadas.

6.3. Consideraciones Éticas y Privacidad

6.3.1. Ética y Privacidad de los Datos

Dada la naturaleza sensible de la información académica procesada, el diseño del sistema ha integrado principios de responsabilidad ética:

- **Anonimización de la información:** El modelo se ha construido asegurando que no existan identificadores personales directos, cumpliendo con la normativa vigente de protección de datos (RGPD) y centrando el análisis exclusivamente en métricas de rendimiento por colectivos y asignaturas.
- **Seguridad en el almacenamiento:** El uso de una base de datos MySQL estructurada permite establecer niveles de acceso controlados, garantizando que la información estratégica de la universidad solo sea accesible para los perfiles autorizados a través del entorno de Power BI.
- **Uso responsable de los resultados:** Se ha enfatizado que las conclusiones del dashboard deben utilizarse como una herramienta de apoyo y acompañamiento al alumnado, evitando sesgos que pudieran estigmatizar a los estudiantes identificados como “repetidores”.

6.3.2. Eficiencia en la Gestión Institucional

La automatización del flujo de datos ha transformado la operativa administrativa de la titulación:

- **Optimización de recursos docentes:** Al identificar las materias con mayor carga de alumnos y menor tasa de éxito, la dirección del centro puede realizar una planificación de profesorado y tutorías mucho más precisa y ajustada a las necesidades reales.
- **Reducción de tiempos de respuesta:** El paso de un análisis manual a uno automatizado reduce el tiempo de generación de informes de semanas a segundos, permitiendo una agilidad operativa que facilita la reacción inmediata ante problemas en el curso actual.
- **Consistencia del dato único:** Se elimina la disparidad de criterios entre diferentes departamentos al establecer una “única fuente de verdad” técnica, lo que evita discusiones sobre la validez de las cifras y centra el esfuerzo en la búsqueda de soluciones.

Bibliografía

- [1] E. Turban, L. Volonino, and G. R. Wood, *Information Technology for Management: Advancing Sustainable, Profitable Business Growth*, 10th ed. John Wiley & Sons, 2015. [Online]. Available: <https://www.wiley.com>
- [2] R. Kimball and J. Caserta, *The Data Warehouse ETL Toolkit: Practical Techniques for Extracting, Cleaning, Conforming, and Delivering Data*. John Wiley & Sons, 2004. [Online]. Available: <https://www.wiley.com>
- [3] R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. John Wiley & Sons, 2013. [Online]. Available: <https://www.wiley.com>
- [4] Gartner Inc. (2025) Gartner glossary: Big data it terminology. [Online]. Available: <https://www.gartner.com/en/information-technology/glossary/big-data>
- [5] Microsoft Corporation. (2026) Online transaction processing (oltp) architecture guide. [Online]. Available: <https://learn.microsoft.com/en-us/azure/architecture/data-guide/relational-data/online-transaction-processing>
- [6] Gartner Inc. (2026) Gartner official research and information technology glossary. [Online]. Available: <https://www.gartner.com>
- [7] ——. (2025) Gartner glossary: Dark data definition. [Online]. Available: <https://www.gartner.com/en/information-technology/glossary/dark-data>
- [8] Microsoft Corporation. (2026) Guía de arquitectura de datos: Extraer, transformar y cargar (etl). [Online]. Available: <https://learn.microsoft.com/es-es/azure/architecture/data-guide/relational-data/etl>
- [9] ——. (2026) Comprender el modelo en estrella y su importancia para power bi. [Online]. Available: <https://learn.microsoft.com/es-es/power-bi/guidance/star-schema-introduction>
- [10] Oracle Corporation. (2021) Oracle database data warehousing guide: The etl staging area. [Online]. Available: <https://docs.oracle.com/cd/B10501.01/server.920/a96520/concept.htm>
- [11] IBM Corporation. (2025) What is batch processing? fundamentals of mainframe and core data architecture. [Online]. Available: <https://www.ibm.com/topics/batch-processing>
- [12] Microsoft Corporation. (2026) Online analytical processing (olap) systems architecture. [Online]. Available: <https://learn.microsoft.com/en-us/azure/architecture/data-guide/relational-data/online-analytical-processing>
- [13] ——. (2026) Data analysis expressions (dax) reference guide. [Online]. Available: <https://learn.microsoft.com/en-us/dax/dax-overview>

- [14] ——. (2025) Planning guide: Enterprise power bi deployment and self-service strategy. [Online]. Available: <https://learn.microsoft.com/en-us/power-bi/guidance/whitepaper-powerbi-enterprise-deployment>
- [15] Snowflake Inc. (2025) The cloud data architecture: Data warehousing as a software-as-a-service (saas). [Online]. Available: <https://www.snowflake.com>
- [16] Microsoft Corporation. (2026) Use power bi q&a to explore your data and create visuals using natural language. [Online]. Available: <https://learn.microsoft.com/en-us/power-bi/consumer/end-user-q-and-a>
- [17] ——. (2026) Visualization types in power bi: Filled maps and heat layers. [Online]. Available: <https://learn.microsoft.com/en-us/power-bi/visuals/power-bi-visualization-filled-maps-heat-maps>
- [18] C. N. Knaflitz, *Storytelling with Data: A Data Visualization Guide for Business Professionals*. John Wiley & Sons, 2015. [Online]. Available: <https://www.storytellingwithdata.com>
- [19] Amazon Web Services, Inc. (2026) What is a data lake? architecture, benefits, and analytics core principles. [Online]. Available: <https://aws.amazon.com/big-data/datalakes-and-analytics/what-is-a-data-lake/>
- [20] Georgia Institute of Technology. (2024) Enterprise data management and institutional research analytics portal. [Online]. Available: <https://ir.gatech.edu>
- [21] E. Phillips and C. Fowler, “Using e-advisor to improve student success and retention at arizona state university,” *EDUCAUSE Review*, 2013. [Online]. Available: <https://er.educause.edu>
- [22] Universidad de Murcia. (2023) Estrategia de universidad digital y almacén de datos corporativo (business intelligence). [Online]. Available: <https://www.um.es/web/digital>
- [23] Microsoft Corporation. (2026) Excel specifications and limits: Csv format and sheet data constraints. [Online]. Available: <https://support.microsoft.com/en-us/excel>
- [24] Talend Inc., *Talend Open Studio for Data Integration: User Manual and Component Reference*, Talend Help Center Platforms, 2024. [Online]. Available: <https://help.talend.com>
- [25] Microsoft Corporation. (2026) Power bi interactive documentation and enterprise product solutions. [Online]. Available: <https://powerbi.microsoft.com>
- [26] S. Chacon and B. Straub, *Pro Git*, 2nd ed. Apress, 2014. [Online]. Available: <https://git-scm.com/book/en/v2>
- [27] V. M. Dominguez Rivas, *Plantilla TFG ETSISI UPM*. ETSISI, 2020.